

# Mustererkennung - Schönherr

Franz Köstner

WS2013/14

# 1 Zum Begriff ME (pattern recognition)

## 1.1 Einordnung des Gebietes

**Erkennung (Klassifikation) von:**

- Bildmustern
- Sprachmustern
- Zeichenmustern
- ...

Muster : Datensatz ( Abstraktion ), zu einer Klasse gehörig

**Unterscheidung von:**

- numerischer Mustererkennung
- Mustererkennung mit KNN
- syntaktische Mustererkennung

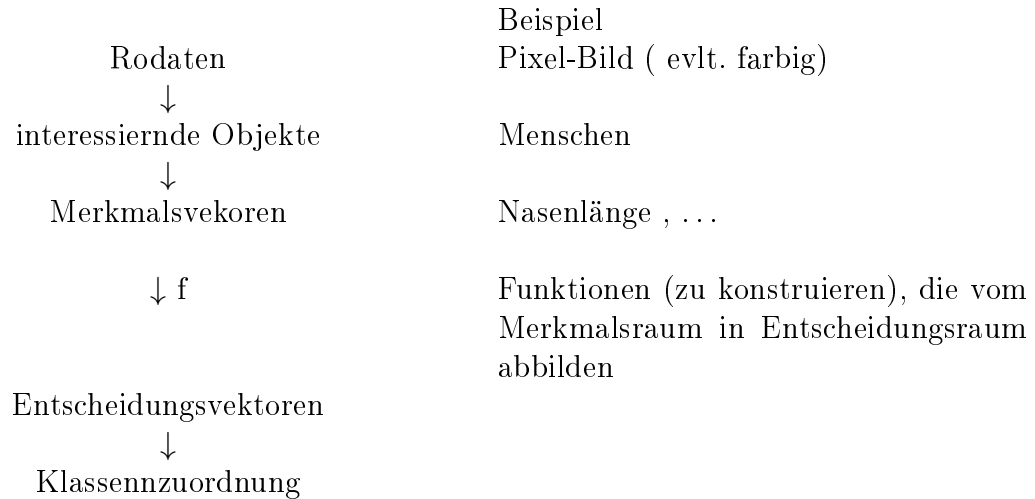
Problem: korrekte Kl.-Einordnung von verschiedenen Formen derselben Objekte

Beispiel: A,  $\bar{A}$ ,  $\forall$

Mustererkennung und Bildverarbeitung ist unterschiedlich hat aber vielen Gemeinsamkeiten

- Bildverarbeitung: Objekte finden
- Mustererkennung: Klassifikation von Objekten

## Typisches Vorgehen (num. Mustererkennung, KNN)



## 1.2 Typische Anwendungen

### (a) Schriftzeichenerkennung

↔ OCR-Software (optical character recognition)

- Bankbelege: ca. 90% Erkennung
- Erkennen gedruckter Schrift
- Handschrift
- Unterschriften-Erkennung

### (b) Objekterkennung

- Werkstück auf Fließband
- Pflanzen zwischen Bahngleisen

### (c) Qualitätskontrolle

- Produktprüfung: Bsp.: Dachziegel (Risse)

### (d) Fernerkundung

- Lagerstätten für Ressourcen
- Waldbeschaffenheit
- Umwelterkennung: Bsp.: Land-Wasser-Grenzen

### (e) medizinische Anwendungen

- EKG
- EEG
- CT-Bilder

- Röntgen-Bilder
  - Mikroskop-Bilder
- (f) Auswertung seismographischer Messungen
- Erdbeben?
- (g) Roboter-Fußball
- Robotererkennung
  - Ballerkennung
  - Spielfeldererkennung
  - Torerkennung
- (h) Sprachverarbeitung
- Worterkennung
  - Sprechererkennung
- (i) Fingerabdruckererkennung
- (j) Gesichtserkennung
- (k) Iriserkennung
- (l) Handerkennung
- (m) CRM-Anwendungen (customer relationship management)

## 1.3 Begriffe und Bezeichnungen

Muster:

$\underbrace{\rightarrow}_{\text{informal}}$  Datensatz (Komponenten mit Funktionen)

$$\underbrace{\rightarrow}_{\text{formal}} f(x) = \begin{pmatrix} cf_1(x_1, x_2, \dots, x_n) \\ \dots \\ f_n(x_1, x_2, \dots, x_n) \end{pmatrix}$$

### **Muster-Beispiele:**

- (a) Sprache (mit Mikrophon aufgenommen)  
 $f(t)$  - elektrischer Spannungsverlauf
- (b) Schwarzweiß-Bild  $f(x,y)$  - Grauwert im Punkt  $(x,y)$

(c) Fernsehbild  $f(x, y, t) = \begin{pmatrix} cf_r(x, y, t) \\ f_g(x, y, t) \\ f_b(x, y, t) \end{pmatrix}$

Mustererkennung - Analyse und Klassifikation von Mustern

Merkmale: Daten zur Beschreibung eines Objektes

- Name
- Datentyp
- Wert

n - Anzahl (relevanter ) Merkmale

Objekt: Menge von Merkmalswerten ( eigentlich Bild eines Objektes)

Klasse: Menge von zusammengehörigen Objekten

Stichprobe: endliche Menge von Objekten

- klassifizierte
- unklassifizierte

Klassifikator: Alg., der Obj. Klassen zuordnet

- Güte des Klassifikators: z.B.  $\frac{\text{AnzahlkorrekterKlassifikationen}}{\text{AnzahlallerKlassifikationen}}$

Lernen eines Klassifikators ( mit Lehrer)

- anhand einer klassifizierten Stichprobe ( iterativ)

Clustern ( ohne Lehrer)

- unüberwachtes “Lernen“, d.h. aufwendige Konstruktion eines Klassifikators

## 1.4 Merkmale und Invarianten

Robustheit der Merkmale gegen Störungen ist wünschenswert

- Robustheit gegen geometrische Transformation
  - Skalierung

- Rotation
- Translation
- Signalrauschen
- Deformationen (Lächeln  $\rightarrow$  Gesichtsdeformation )

Invarianz geben alle Störungen unmöglich

### 1.4.1 Invarianten

Merkmale, die bezüglich bestimmten Transformation konstant sind:

- Flächeninhalte invariant gegen Translation und Rotation (kann bei Rundungen Fehler erzeugen)
- aber nicht gegen Skalierung

#### **Invariantentheorie:**

Welche Merkmale sind gegen welche Transformation invariant?

Motivation:

Erkennen von gestörten Mustern

#### **wichtige Transformationen:**

- Skalierung:  $y = c \cdot x$  (  $c$  ist Konstante )
- Translation:  $y = x + a$  (  $a$  ist konstanter Vektor )
- Rotation um:
  - Winkel  $\varphi$
  - \* gegen: UZS:  $y = \begin{pmatrix} c \cos \varphi & -\sin \varphi \\ \sin \varphi & c \cos \varphi \end{pmatrix} x$
- affine Transformation:  $y = A x + a$  (  $A$ : Matrix,  $a$  geg. Vektor)
- Projektion  $y_1 = \frac{a_1 0 + a_1 1 x_1 + a_1 2 x_2}{1 + a_3 1 x_1 + a_3 2 x_2}$   
 $y_2 = \frac{a_2 0 + a_2 1 x_1 + a_2 2 x_2}{1 + a_3 1 x_1 + a_3 2 x_2}$

Affine Invarianten - ein Beispiel

$p_0, p_1, p_2, p$  - 4 Punkte

sodass  $p_1 - p_0$  und  $p_2 - p_0$  linear unabhängig sind

dann existieren  $\lambda_1, \lambda_2$  , so dass

$$p = p_0 + \lambda_1(p_1 - p_0) + \lambda_2(p_2 - p_0)$$




Abbildung 1.1: Beispiel:  $p = 0.5(p_1 - p_0) + 2(p_2 - p_0)$

$Ap + a = Ap_0 + a + \lambda_1(A_1 + a - A_0 - a) + \lambda_2(A_2 + a - A_0 - a) \hookrightarrow \lambda_1, \lambda_2$  invariant gegen affine Transformationen

Wichtig: Entsprechung der Basispunkte

$p - q, p_1 - q_1, \dots$  zu garantieren (per Augenmaß)

Diese Aufgabe ist ein Referenzproblem

Danach  $A, a$  bestimmbar

Eigenschaft affiner Transformationen:

- Geraden gehen in Geraden über. (Collinearität)
- Abstände von Punkte ändern sich um einen gemeinsamen Faktor. Bei Projektiven Transformationen gibt es keinen gemeinsamen Faktor. Projektive Transformationen sind auch collinear.


Das Doppelverhältnis:

Situationsbeschreibung

4 collineare Punkte in einem Referenzmuster gegeben ( $x_i$ )

4 Bildpunkte (nach proj. Abbildung) gegeben ( $y_i$ )

Annahme: Referenzproblem gelöst



$$\text{Doppelverhältnis: } DV(x) = \frac{\frac{x_1 - x_2}{x_1 - x_3}}{\frac{x_4 - x_2}{x_4 - x_3}}$$

**Satz:**  $DV(x) = DV(y)$ , d.h. Invarianz gegen proj. Transformation

**Übung:** Aufgabe1:

Aufnahmen von zwei projektiven Kameras. Es existieren in Bild 1 4 Charakteristische Punkte.

- $P_1 = (0, 1)$
- $P_2 = (3, 10)$
- $P_3 = (4, 13)$
- $P_4 = (6, 19)$

Das zweite Bild enthält eine möglicherweise entsprechende Strecke.

- $Q_1 = (-13, 26)$
- $Q_2 = (-\frac{13}{7}, \frac{26}{7})$
- $Q_2 = (-\frac{13}{9}, \frac{26}{9})$
- $Q_2 = (-1, 2)$

Doppelverhältnis von q = 0.5

Doppelverhältnis von p = 0.5

Aufgabe2:

- $P_1 = (0, 3)$
- $P_2 = (1, 2)$
- $P_3 = (2, 1)$
- $P_4 = (3, 0)$

Das zweite Bild enthält eine Möglicherweise entsprechende Strecke mit den mutmaßlich entsprechenden Punkten  $q_1$  bis  $q_3$ .

- $Q_1 = (0, 6)$
- $Q_2 = (2, 4)$
- $Q_2 = (4, 2)$

Wo müsste ein vierter Referenzpunkt gefunden werden? Lösung:  $q_4 = (0, 6)$



## 1.4.2 Flächeninvarianten

### (a) Determinantenmethode

Berechnung von Streckenlängen, Dreiecksflächen, Tetraedervolumina, ... können mittels der Eckpunkte mithilfe von Determinanten berechnet werden. Untersuchung des Verhaltens von Determinanten bei Transformationen  $\rightarrow$  mögliche eine Reihe von Determinanten abzuleiten

### (b) Formfaktor F

$$F = \frac{u^2}{4f}$$

u - Umfang

f - Fläche

Beispiel: Kreis mit Durchmesser 1

$$F(\text{Kreis}) = \frac{(\pi \cdot d)^2}{4 \cdot \pi \cdot d^2} = \pi$$

$$F(\text{Quadrat}) = \frac{(4 \cdot a)^2}{4 \cdot a^2} = 4$$

F beschreibt die Unrundheit einer Fläche

Im Allgemeinen ist kein Rückschluss auf die Form möglich.

## 1.4.3 Momente

Berechnung von geometrischen Momenten:

F sei eine Fläche (z.B. Kreis)

Momente der Ordnung  $p + q$

$$M_{pq} = \iint_F x^p \cdot y^q dx dy$$

Interpretation von Momenten

$M_{00}$  = Fläche von F

$M_{10}/M_{00}$  = X-Koordinate des Schwerpunktes

$M_{01}/M_{00}$  = Y-Koordinate des Schwerpunktes

$M_{20}, M_{02}$  = Trägheitsmomente bezüglich Koordinaten-Achsen

$M_{20} + M_{02}$  = polares Trägheitsmoment bezüglich (0,0)

$M_{11}$  = ?

gegeben: flächenhaftes Objekt

Berechnung des Schwerpunktes

Translation der Fläche, so dass Schwerpunkt auf (0,0) liegt.

$\hookrightarrow$  Fläche F

## 1.4.4 Die Trägheitsellipse

**Definition:** Die Ellipse

$$M_{20} * x^2 + 2 * M_{11} * x * y + M_{02} * y^2 = 1$$

heißt Trägheitsellipse in Mittelpunktelage einer Fläche F.

Bemerkung: Es gilt immer  $M_{20} * M_{02} \geq M_{11}^2$ , so dass es sich wirklich um eine Ellipse handelt.

**Definition:** Neigung von F gegen X-Achse = Neigung der Trägheitsellipse von F gegen X-Achse

**Zielstellung:** Feststellen des Neigungswinkels von F

F samt Ellipse wird entgegen dem Uhrzeigersinn um den Winkel  $\varphi$  gedreht. ( um Koordinatenursprung )

$\hookrightarrow$  neues (u,v)-Koordinatensystem

Im neuen System soll die Ellipse in Hauptachsenlage liegen, dass heißt  $\varphi$  ist passend zu wählen.

Berechnung der neuen Momente 2. Ordnung (nach Drehung):

$$M_{20}(\varphi) = \iint_{F'} v^2 dv du \quad (F' : F \text{ im (u,v)-System})$$

$$= \iint_F (x + \cos(\varphi) - y - \sin(\varphi))^2 dx dy$$

$$= \iint_F (x^2 + \cos^2(\varphi) - 2 * x * y * \sin(\varphi) * \cos(\varphi) + y^2 * \sin^2(\varphi)) dx dy$$

$$= M_{20} + \cos^2(\varphi) - 2 * M_{11} * \sin(\varphi) * \cos(\varphi) + M_{02} * \sin^2(\varphi)$$

$$\text{Ebenso ergibt sich } M_{02}(\varphi) = M_{02} + \sin^2(\varphi) + 2 * M_{11} * \sin(\varphi) * \cos(\varphi) + M_{20} * \cos^2(\varphi)$$

Ferner gilt:

$$M_{11}(\varphi) = \iint u * v du dv$$

$$= \iint_F (x * \cos(\varphi) - y * \sin(\varphi)) * (x * \sin(\varphi) + y * \cos(\varphi)) dx dy$$

$$= \iint_F (x^2 * \sin(\varphi) * \cos(\varphi)) dx dy - \iint_F (x * y * \cos^2(\varphi)) dx dy + \iint_F (x * y * \sin^2(\varphi)) dx dy - \iint_F (y^2 * \sin(\varphi) * \cos(\varphi)) dx dy$$

$$= (M_{20} - M_{02}) * \sin(\varphi) * \cos(\varphi) + M_{11} * (\cos^2(\varphi) - \sin^2(\varphi))$$

Nullsetzen dieses Ausdrucks ( also  $M_{11}(\varphi)$  ), wenn Hauptachsenlage der Trägheitsellipse im (u,v)-System zu erreichen.

Division durch  $\cos^2(\varphi) (\varphi \neq \frac{\pi}{2}) \rightarrow$  Übergang zum Tangens

$$\hookrightarrow 0 = (M_{20} - M_{02} * \tan(\varphi) + M_{11} * (1 - \tan^2(\varphi)))$$

Dividieren durch  $M_{20} - M_{02}$  und durch  $(1 - \tan^2(\varphi))$  und \* 2

$$\frac{2 * M_{11}}{M_{02} - M_{20}} = \frac{2 * \tan(\varphi)}{1 - \tan^2(\varphi)} = \tan(2 * \varphi) \quad (\varphi \neq \frac{\pi}{4})$$

$$\hookrightarrow q = \frac{1}{2} * \arctan\left(\frac{2 * M_{11}}{M_{02} - M_{20}}\right)$$

Die Berechnung ist nicht möglich bei Gleichheit von  $M_{20}$  und  $M_{02}$  Gründe dafür sind mögliche Regelmäßigkeiten der Fläche - Beispiele sind regelmäßige Polygone oder ein Rechteck, welches von der Normalelage um  $45^\circ$  gedreht ist.

Bemerkung: Wenn eine Fläche gedreht wird, dreht sich die zugehörige Trägheitsellipse

automatisch mit.

Ellipsengleichung im Hauptachsenlage (allgemein)

$$\frac{u^2}{a^2} + \frac{v^2}{b^2} = 1$$

a - Länge vom (0,0) bis zum linken/rechten Scheitelpunkt

b - Länge vom (0,0) bis zum unteren/oberen Scheitelpunkt

Setze (passend gewählt):

$$a = \frac{1}{\sqrt{M_{20}(\varphi)}} \quad b = \frac{1}{\sqrt{M_{02}(\varphi)}}$$

↓

$$M_{20}(\varphi)v^2 + M_{02}(\varphi)v^2 = 1$$

Ausblick:

- (a) Übertragung zur komplexen Ebene ( $x + iy$ ) - Berechnung komplexer Momente  
Bekannt:  $H_v$ -Invarianten ( $H_1, \dots, H_{12}$ )
- (b) Berechnung von Linienmomenten mit Kurvenintegralen

## 2 Mustervergleich (Matching)

### 2.1 Abstandsmaße

**Referenzmuster** (template) sei gegeben - mit mathematischem Modell  
beziehungweise für jede Klasse ein Referenzmuster  $\rightarrow$  modellbasiertes Matching

Problem: neues Muster ähnlich zu einem Referenzmuster?

Berücksichtigung von:

- Position
- Skalierung
- evtl. Rotation
- Orientierung

Muster durch Signalwerte gegeben:

Beispiel: Grauwerte im interessierenden Gebiet  $G$

$r(x,y)$  - Grauwerte der Referenzmusters,  $(x,y) \in G$

$f(x,y)$  - Grauwerte eines gegebenen Bildes

Abstand zwischen 2 Bildern ( Bsp )

$$a_1 = \max | f(x,y) - r(x,y) |, (x,y) \in G$$

$$a_2 = \iint_G (f(x,y) - r(x,y))^2 dx dy$$

$$a_3 = \sum_{(x,y) \in G} (f(x,y) - r(x,y))^2 dx dy$$

Fall qualitative Merkmale: Hamming-Distanz

$$a_4 = \sum_i |x_i - y_i|$$

#### 2.1.1 Abstand endlicher Punktmengen

Nutzung für:

- Objekterkennung in Bildern

- Handschrifterkennung

$A, B \dots$  endliche Punktmenge

Abstand zweier Punkte:

$d(a, b) = \|a - b\|$ , mit  $\|x\|$  gleich Norm von  $x$

Abstand eines Punktes  $a$  von Punktmenge  $B$ :

$$d(a, B) = \min_{b \in B} \|a - b\| \text{ BILD1}$$

Abstand zweier Punktmenge:

$n(A)$  = Anzahl der Elemente in  $A$

$n(B)$  = Anzahl der Elemente in  $B$

$$d_1(A, B) = \min_{a \in A} d(a, B)$$

BILD2

$d_1(A, B) = 0$  bei Gleichheit zweier Punkte  $a, b$

$$d_2(A, B) = \max_{a \in A} d(a, B)$$

$$d_3(A, B) = \frac{1}{n(A)} \sum_{a \in A} d(a, B), \text{ mit } n(X) \text{ gleich Anzahl der Punkte in } X$$

**Ungerichtete Abstandsmaße:** Irgendein Abstandsmaß  $d(A, B)$  sei gegeben.

$$u_1 = \min\{d(A, B), d(B, A)\}$$

$$u_2 = \max\{d(A, B), d(B, A)\}$$

$$u_3 = \frac{d(A, B) + d(B, A)}{2}$$

$$u_4 = \frac{n(A) \cdot d(A, B) + n(B) \cdot d(B, A)}{n(A) + n(B)}$$

Wichtig: Robustheit gegenüber Störungen!

Hausdorff-Metrik ( $d_2$  mit  $u_2$ ) eher ungeeignet wegen max

Kombination von  $d_3$  mit  $u_2$  ist günstig:

$$u(A, B) = \max \left\{ \frac{1}{n(A)} \sum_{a \in A} d(a, B), \frac{1}{n(B)} \sum_{b \in B} d(b, A) \right\}$$

### 2.1.2 Korrelationsmaße als Matching-Maße

$x, y \dots$  Muster-Vektoren zum Beispiel Pixel-Grauwerte

$$m = \frac{\langle x, y \rangle}{\|x\| \cdot \|y\|}, \text{ dann } -1 \leq m \leq 1 \text{ und } x = y \rightarrow m = 1$$

Falls  $y = k \cdot x$ , gilt:  $m$  ist invariant gegen  $k$  ( $k \neq 0$ ) ( $k$  ist Konstante für den Kontrastunterschied)

$y = x + h$  mit  $h$  gleich Vektor mit identischen Komponenten

Bilder werden (bei großen  $h$ -Werten) als verschieden bewertet.

m sollte invariant sein gegen Kontrast- und Helligkeitsänderung.

**Neudefinition des Matching-Maßes:**  $x'$  ist der Vektor mit Durchschnittshelligkeit von  $x$  als Komponenten

$y'$  ist der Vektor mit Durchschnittshelligkeit von  $y$  als Komponenten

Ersetzen von  $x$  durch  $x - x'$  und  $y$  durch  $y - y'$  in der  $m$ -Formel. Dadurch ergibt sich die zyklische Kreuzkorrelation  $m'$ :

$$m' = \frac{\langle x - x', y - y' \rangle}{\|x - x'\| \cdot \|y - y'\|}$$

**Prüfung mit 2 pixelbilder: objekt in der hauptdiagonale gleich? helligkeitsverschiebung?  $m'$  benutzen. Antwort: sind unterschiedliche Objekte, bzw. man kann davon ausgehen das es die selben Objekte sein könnten**

## 2.2 Normalisierung zweier endlicher Punktmengen

Problem: 2 Mengen  $A(x, y), B(u, v)$  die möglicherweise dasselbe Objekt darstellen.  $u = f_1(x, y)$  und  $v = f_2(x, y)$  (eine Menge Bild der anderen)

$f = \begin{pmatrix} f_1 \\ f_2 \end{pmatrix}$  ist damit eine unbekannte Koordinatentransformation.

### 2.2.1 Berechnung von MSE (mean square error)

$$MSE = \sum_i w_i \cdot [(u_i - f_1(x_i, y_i))^2 + (v_i - f_2(x_i, y_i))^2] \rightarrow \min$$

mit  $w_i$  gleich gegebene Gewichte, der Bedeutung der Punkte entsprechend zu wählen.

Zum Beispiel:  $w_i \geq 0 \wedge \sum_i w_i = 1$

oder:  $\underbrace{\forall i : w_i = 1}_{\text{bei Gleichwertigkeit}}$

Variabel sind dabei die Parameter von  $f$ . (stehen nicht mit in der Formel)

Voraussetzung:  $A, B$  haben gleiche Kardinalität.

Zuordnung  $(u_i, v_i) \leftrightarrow (x_i, y_i)$  müssen bekannt sein, das heißt alle Referenz-Probleme gelöst. Die Voraussetzung ist damit praktisch nie erfüllt.

### 2.2.2 Heuristisches Verfahren zur näherungsweisen Lösung für $MSE \rightarrow \min$ für beliebige Punktmengen und ohne bekannte Referenzbeziehungen:

0.  $A$  wird mittels  $f^{(0)} = \begin{pmatrix} f_1^{(0)} \\ f_2^{(0)} \end{pmatrix}$  so transformiert, dass danach  $A$  mit  $B$  “grob” deckungsgleich ist.  $f^{(0)}(A) \approx B$
1. Für alle  $a \in A$  wird ein  $b \in B$  bestimmt mit Abstand  $d(a, B)$ . Sammeln dieser Pseudo-Referenz Paare in einer Liste  $L$
2. Für alle  $b \in B$  wird ein  $a \in A$  bestimmt mit Abstand  $d(b, A)$ . Sammeln dieser Pseudo-Referenz Paare in einer Liste  $L$
3.  $i = i + 1$   
Berechnung einer Transformation  $f^{(i)}$  durch Minimierung von MSE in Bezug auf die Pseudo-Ref-Paare
4.  $A = f^{(i)}(A)$
5. Gütekontrolle  $d(A, B)$  genügend klein?  
Falls ja, Stop mit Erfolg  
Falls nein, goto 1  
Falls  $d(A, B)$  nach zahlreichen Iterationen zu groß, dann STOP ohne Erfolg

## 2.3 Die Hough-Transformation

Detektion von geraden Linien in einem Bild (meist Konturlinien)

Gegebenfalls Vorverarbeitung: Konturen filtern (mit Sobel-Filter, Canny-Filter)

Grundlage: Hesse'sche Normalform der Normalengleichung.

**Übliche Geradengleichung:**  $a * x + b * y + c = 0$  (Wenn  $b = 0 \rightarrow$  Gleichung nicht auflösbar nach  $y \rightarrow$  parallel zu  $y$ )

$l$  ist die Länge des Lotes von  $(0, 0)$  zur Geraden, mit  $(0, 0) \notin$  Gerade.

$\varphi$  ist der Winkel des Lotes zur  $x$ -Achse.

$$l = x * \cos \varphi + y * \sin \varphi$$

Bild der Geraden im  $(l, \varphi)$ -Koordinatensystem (Hough-Raum) ist ein Punkt, denn  $l$  und  $\varphi$  determinieren die Gerade.

Beispiel:

$$y_1 : 2 * x - y - 3 = 0$$

$$y_2 : y - 2 = 0$$

Bild3

### 2.3.1 Praktisches Vorgehen (zur Liniendetektion)

Diskretisierung des Hough-Raumes  $\rightarrow$  rechteckiges Punktfeld

Zuordnung einer Zählvariablen zu jeden solchen Punkt (anfangs 0).

Bemerkung: Jedem Pixel im H-Raum entspricht eine Gerade im  $(x, y)$ -Raum

Berechnung aller Geradenstücke aus Vordergrundpixel im Urbild. Erhöhung der jeweiligen Zählvariablen im H-Raum zu jedem Geradenstück. Danach werden die Zählvariablen mit höchsten Werten ermittelt. Denen entsprechen die wichtigsten Strecken im Urbild. Literatur: Haberäcker

Erweiterung möglich auf Kreise, Ellipsen, ...

## 2.4 Matching-Möglichkeiten

### 2.4.1 Signalorientiertes Matching

Bezeichnung für die bisher beschriebenen Vorgehensweisen Grund: direktes Matchen gemessener Signalwerte (Grauwerte von Pixeln)

### 2.4.2 Merkmalsorientiertes Matching

Matchen auf Grund von Signalwerten abgeleiteter Werte (z.B.: Merkmale, Hough-Koordinaten, ...)

siehe Kapitel 3

### 2.4.3 Stereo-Matching

Aufgabe: Erkennung von 3D-Objekten aus verschiedenen 2D-Bildern

Problem: Referenz-Problem lösen bei projektiver Verzerrung Erkennungsalgorithmus verwenden

### 2.4.4 Graph-Matching

Modellierung komplexer Szenen als Graphen.

Erkennung von Teil-Szenen:

- Kommt ein Graph in einem anderen vor?
- Sind 2 Graphen gleich?



# 3 Numerische Klassifikation

## 3.1 Aufgabenstellung

$E^n$  wird betrachtet, heißt Merkmalsraum (n-dim Euklidischer Raum)

Objekt  $O$ : Repräsentation als  $n$ -dimensionaler Messwerte-Vektor

$m$ -Anzahl der Klassen

$K_i$ :  $i$ -te Klasse

**Gesucht:** Zerlegung von  $E^n$  in  $m$  Gebiete  $G_i$ , so dass

$$E^n = \bigcup_{i=1}^m G_i$$

$$\forall i \forall j i \neq j \rightarrow G_i \cap G_j = \emptyset$$

Klassifikator ordnet einem Objekt  $O$   $K_i$  zu, falls  $x \in G_i$ , mit  $x$  Bild von  $O$  Problem: Zerlegung soll möglichst gut sein:

- entsprechend der Bedeutung der Klasse
- möglichst weniger Echklassifikationen

Ggf. (m+1)-tes Gebiet als Rückweisegebiet vorsehen.

### 3.1.1 Geometrische Modelle

Die  $G_i$  (Modell) werden mit Musterklassen (Realität) identifiziert.  $O \in K_i \Leftrightarrow x \in G_i$

### 3.1.2 Stochastische Modelle

Klassifiziert wird nach  $x \in G_i$ , was nicht  $O \in K_i$  bedeuten muss!

Ursache: Kriterien, die der Klassifikator nicht "kennt". (unvollständige Modellierung)

Bsp.: Menschen in Erkältete und Nichterkältete einteilen Klass.-Kriterien: husten oder niesen = true

## 3.2 Geometrische Klassifikationsmodelle

### 3.2.1 Trennfunktionen

Mehrere Punktmengen in  $E^n$  gegeben

**Definition:**  $P_1, P_2 \subset E_n$  heißt linear separierbar, falls es eine Hyperebene

$$a^\top x + b = 0$$

gibt, so dass

$$a^\top x + b > 0, \text{ für } x \in P_1$$

und

$$a^\top x + b < 0, \text{ für } x \in P_2$$

.

Bei 3 separierbaren Klassen in  $E^2$  sind 3 Geraden zur Klassifikation erforderlich. Allgemein:  $m$ -Klassen in  $E^n$  dann

$$\frac{m(m-1)}{2}$$

Trenn-Hyperebenen zu konstruieren.

Lineare ist Separierbarkeit nicht offensichtlich.

### 3.2.2 Diskriminanzfunktionen

Generelle Idee: Konstruktion einer Menge von Funktionen ( $m$  Funktionen)  $d_i$ .

$x$  gehört zu  $K_i$ , wenn  $d_i(x) > d_j(x)$ , für  $i \neq j$

**Definition:**  $E^n$  vollständig in  $m$  Gebiete  $G_i$  zerlegt.

$m$  auf  $E^n$  stetige Funktionen  $d_i(x)$  heißen Diskriminanzfunktionen, wenn für alle Nicht-Randpunkte gilt:

$$\forall k \forall j [x \in G_k \wedge k \neq j \rightarrow d_k(x) > d_j(x)]$$

Trennfunktion zweier Gebiete  $G_i, G_j$  ist spezifisch durch die Gleichung:

$$d_i(x) = d_j(x)$$

Lösung des Klassifikations-Problem durch Berechnung des **Klassen-Index** nach

$$k = \text{index} \left\{ \max_i d_i(x) \right\}$$

## Konstruktion spezieller Diskriminanzfunktionen

### 1. Minimum-Distanz-Klassifikator

Idee: Beschreibung der Klassen durch Referenzmuster (oder Zentren)  $z_i$ .

Klassifikation:  $x$  wird Klasse  $K_i$  zugeordnet, wenn der Abstand von  $x$  zu  $z_i$  minimal ist.

Euklidischer Abstand  $a(x, z_i)$  zwischen  $x$  und  $z_i$

$$a_1^2(x, z_i) = \|x - z_i\|^2 = x^T x - 2z_i^T x + z_i^T z_i$$

Bemerkung:  $a$  oder  $a^2$  ist gleichgültig wegen Monotonie von  $(\cdot)^2$ . Die Konstante (bezüglich  $i$ )  $x^T x$  auch irrelevant.

Diskriminanzfunktion:  $d_i(x) = z_i^T z_i - 2z_i^T x$

$Klassenindex_i$  linear bezüglich  $x$

$$k = index\left\{\min_{1 \leq i \leq m} d_i(x)\right\}$$

Trennfläche zwischen 2 Klassen  $K_i$  und  $K_j$   $d_i(x) = d_j(x) \rightarrow$  vollständige Zerlegung des  $E^n$

### 2. NN-Klassifikator (nächster Nachbar)

Im allgemeinen eine zu ungenaue Beschreibung einer Klasse durch nur ein Zentrum  $z_i \rightarrow$  Idee: mehrere Referenzmuster pro Klasse.

$K_i$ : Zentren  $z_i(j)$   $1 \leq j \leq J(i)$  mit  $J$  Anzahl der Zentren für  $K_i$ .

Diskriminanzfunktion (stückweise linear):

$$d_i(x) = \min_{1 \leq j \leq J(i)} \{z_i(j)^T \cdot z_i(j) - 2 \cdot z_i(j)^T \cdot x\}$$

$$k = index\left\{\min_i d_i(x)\right\}$$

### 3. KNN-Klassifikator

Verbesserung des NN-Klassifikators, indem Ausreißer schwächer berücksichtigt werden.

$x$  sei gegeben und zu klassifizieren

Idee: Berechnung aller

$$d_{ij}(x) = z_i(j)^T \cdot z_i(j) - 2 \cdot z_i(j)^T \cdot x$$

, d.h.  $\sum_i d(i)$  Werte

- $i$  - Klassenindex
- $j$  - Zentrenindex in  $K_i$

Auswahl der  $k$  kleinsten  $d_{ij}(x)$  ( $k$  gegeben).

Klassifikationsregel: Zuordnung von  $x$  zu  $K_i$ , wenn für  $i = |$  die meisten  $d_{ij}(x)$

unter den  $k$  kleinsten vorkommen.

Nichteindeutigkeit ist möglich.

Entscheidung z.B. nach minimaler Summe der entsprechenden  $d_{ij}$ . Eventuell besser: ... der entsprechenden Abstände

Festlegung von  $k$ :

$k$  groß  $\rightarrow$  schwächerer Einfluss von Ausreißern

$k = 1 \rightarrow$  NN-Klassifikator

#### 4. Andere Diskriminanzfunktionen

- $d(x) = c^T f(x)$  mit  $f(x)$  fest vorgegeben
- Polynome  $\rightarrow$  Polynom-Klassifikator

#### 5. Klassifikation mit Rückweisegebiet

Zentren  $z_i$  festlegen

Festlegung von -Hyperquadern, -kugeln, -ellipsen um die  $z_i$  herum.

$x$  zu Klassifizieren,  $z_7$  am nächsten aber nicht im *Hyperquader*<sub>7</sub>  $\rightarrow$  Rückweisung

### 3.2.3 Baumklassifikator

Idee:

- Konstruktion achsenparalleler Hyperquader (möglicherweise Vereinigungen zugelassen)
- Beschreibung des  $i$ -ten Quaders ( $1 \leq i \leq m$ ) durch dessen Extrempunkte:  $p[i]$  und  $q[i]$
- Klassifikator:  $x \in K_i \leftrightarrow p_j[i] \leq x_j \leq q_j[i]$  mit  $i$ -Klassen- und  $j$ -Komponenten-Index
- Bestimmung von  $p[i]$  und  $q[i]$ :  
 $x_1, \dots, x_s$  ist eine vorklassifizierte Punktmenge

$$p_j[i] = \min_{r: x[r] \in K_i} \{x_j[r]\}, q_j[i] = \max_{r: x[r] \in K_i} \{x_j[r]\}$$

Problem:

- empfindlich gegen Ausreißer in der Punktmenge wegen min und max
- Bestimmung aller  $p_j$  und  $q_j$  nicht immer erforderlich

Problem - Überlappung von Quadern:

- Zurückweisung bei  $x \in \text{Überlappungsgebiet}$
- Zuweisung zu genau einer Klasse (Zusatz-Regeln erfinden)
- Zuweisung zu mehreren Klassen

## 3.3 Stochastische Klassifizierungs-Modelle

### 3.3.1 Problemstellung

$m$  oder  $m + 1$  Gebiete des  $E^n$  (gegebenenfalls ein Rückweisungsgebiet)  
Vollständige Zerlegung des  $E^n$  ist gesucht, dabei soll es  $m$  echte Klassen geben.

$X$ -  $n$  Komponenten zur Beschreibung eines zufälligen Objekts

$Y$ -Zufallsgröße: Bedeutung  $Y = i \leftrightarrow$  zufälliges Objekt  $X \in K_i$

$f(x)$ - Dichte (stetig) von  $X$ , wobei  $x$   $n$ -dimensionaler Vektor  
Ableitung von  $P(X \leq x)$  - einmal pro Komponente von  $x$

$f(x|y = i)$ - bedingte Dichte von  $X$  unter der Bedingung, dass  $y = i$ . Das heißt Ableitung(nach jeder der Komponenten von  $x$ ) von  $P(X \leq x|Y = i)$

Bemerkung: Stetigkeit von  $f(x) \rightarrow$  Voraussetzungen des Satzes von Schwarz

Von Interesse ist die Beziehung zwischen  $f(x)$  und  $f(x|Y = i)$ . Nach Satz von der totalen Wahrscheinlichkeit gilt:

$$P(X \in (x, x + h]) = \sum_{i=1}^m P(X \in (x, x + h]|Y = i) \cdot P(Y = i)$$

linke Seite:

$$P(X \in (x, x + h]) = \int_{x_1}^{x_1+h_1} \dots \int_{x_n}^{x_n+h_n} f(y_1, \dots, y_n) dy_n \dots dy_1$$

Division durch alle  $h_i$  und  $h_i \rightarrow 0$

$$\hookrightarrow f(x) = \frac{\partial^n P(X_1 \leq x_1, \dots, X_n \leq x_n)}{\partial x_1 \dots \partial x_n}$$

rechte Seite:

$P(x \in (x, x + h|Y = i]$  wird analog behandelt

Ergebnis:

$$f(x|Y = i)$$

Also:

$$f(x) = \sum_{i=1}^m f(x|Y=i) + P(Y=i)$$

Ferner von Interesse:

$$P(Y=i|X=x)$$

d.h. Wahrscheinlichkeit für  $\{\text{Objekt} \in K_i\}$ , wenn Vektor  $x$  beobachtet wurde.

Ausgangspunkt:

$$P(Y=i \wedge X \in (x, x+h])$$

Umformung auf 2 verschiedene Arten:

- einmal 1. Ereignis
- einmal 2. Ereignis

in Bedingung schreiben

$$\begin{aligned} P(Y=i|X \in (x, x+h]) &= P(X \in (x, x+h]|Y=i) * P(Y=i) \\ &= P(X \in (x, x+h]|Y=i) * P(Y=i) \end{aligned}$$

Dann Division von  $P(X \in (x, x+h])$ , sowie das Prod.  $h_1 * \dots * h_n$  im Zähler und Nenner der rechten Seite und dann  $h_i \rightarrow 0$

$$P(Y=i|X=x) = \frac{P(Y=i) \cdot f(x|Y=i)}{f(x)} = p_i(x)$$

Begriffe:

$P(Y=i)$  - A-priori-Wahrscheinlichkeit, dass heißt ist Wahrscheinlichkeit für  $Y=i$  ohne Zusatzwissen

$P(Y=i|X=x)$  - A-posteriori-Wahrscheinlichkeit, dass heißt die Wahrscheinlichkeit für  $Y=i$  nach dem  $X=x$  bekannt ist

### 3.3.2 Klassifizierung mittels A-posteriori-Wahrscheinlichkeit

Beschreibung des Klassenindex nach:

$$k = \text{index}\{\max_i p_i(x)\}$$

**Bemerkung:**

- keine Aussage über Fehlklassifikation
- Dichten gegebenenfalls Schätzung oder approximieren

### 3.3.3 Bayes-Strategie

Einführung einer Kostenmatrix  $(k_{ij})$  mit den Elementen:

$k_{ij}$  ... Kosten bei Eintreten des Ereignisses  $\{Y = i, X \in G_j\}$

Damit erhält man eine Bestrafung von Fehlklassifikationen

Zufallsgröße  $K$  (Kosten):  $K = k_{ij} \leftrightarrow \{Y = i, X \in G_j\}$

Einführung von:

$$p_{ij} = P(Y = i, X \in G_j) = P(Y = i) \cdot P(X \in G_j | Y = i)$$

$$= P(Y = i) \cdot \int_{G_j} f(x | Y = i) dx$$

A-priori-Wahrscheinlichkeit ist bekannt

mittlere Kosten (mittleres Risiko):

$$\begin{aligned} EK &= \sum_{i=1}^m \sum_{j=1}^m k_{ij} * p_{ij} \\ &= \sum_{i=1}^m \sum_{j=1}^m k_{ij} * P(Y = i) * \int_{G_j} f(x | Y = i) dx \end{aligned}$$

$EK$  muss minimiert werden. Variabel sind die Gebietsgrenzen.

Aufgabe:  $G_i$  so zu wählen, dass  $EK$  minimal wird.

Übliche Voraussetzungen:  $K_{ij} = 0$  für alle  $i$ .

$$\hookrightarrow EK = \sum_{j=1}^m \int_{G_j} \sum_{i=1, i \neq j}^m k_{ij} * P(Y = i) * f(x | Y = i) dx$$

### Bayes-Optimalität

Die Zerlegung  $\{G_j\}$  des  $E^n$  heißt Bayes-optimal, wenn für ein beliebiges  $j$  und einem  $x \in \text{int}(G_i)$  (int - interior: alle punkte, ohne Randpunkte einer Fläche) gilt:

$$(*) \forall l : l \neq j \rightarrow \sum_{i=1, i \neq j}^m k_{ij} \cdot P(Y = i) \cdot f(X | Y = i)$$

$$< \sum_{i=1, i \neq l}^m k_{il} \cdot P(Y = i) \cdot f(X | Y = i)$$

Also: Die  $j$ -te Spaltensumme muss kleiner sein als die anderen für innere Punkte von  $G_j$

**Satz:** Bedingung (\*) ist notwendig und hinreichend für die Optimalität von  $EK$  (die Lösung ist im allgemeinen nicht eindeutig)

**Bemerkung:** Summen über  $i$  als Diskriminanzfunktion nutzbar.

Die  $G_j$  sind mit den Bedingungen (\*) determiniert, aber nicht bekannt.

**Klassifikation:** Wenn (\*) gilt, dann Klasse  $j$ .

Das Integral über die  $j$ -te Spaltensumme sind die erwarteten Fehlklassifikations-Kosten

Veranschaulichung für 3 Klassen, also  $m = 3$ , also  $(3, 3)$ -Kostenmatrix:

$$EK = \begin{bmatrix} k_{12} * P(Y = 1) * \int_{G_2} f(x|Y = 1)dx & k_{13} * P(Y = 1) * \int_{G_3} f(x|Y = 1)dx \\ k_{21} * P(Y = 2) * \int_{G_1} f(x|Y = 2)dx & k_{23} * P(Y = 2) * \int_{G_3} f(x|Y = 2)dx \\ k_{31} * P(Y = 3) * \int_{G_1} f(x|Y = 3)dx & k_{32} * P(Y = 3) * \int_{G_2} f(x|Y = 3)dx \end{bmatrix}$$

Bayes-Optimalität Matrix  $\{k_{ij}P(Y = i)f(x|Y = i)\}$  bilden  $j$ -te Spaltensumme kleiner als die anderen  $\leftrightarrow$  Klasse  $j$ , also  $x \in G_j$

Betrachten von Spezialfällen:

- **SF1:**  $k_{ij} = k$  für  $i, j = 1, \dots, m$  mit  $i \neq j$  und  $\forall i k_{ii} = 0$

$$EK = k * \sum_{i=1}^m \sum_{j=0 \wedge i \neq j}^m p_{ij}$$

Bayes-Optimalität: Es sei  $x \in G_j$

$$\forall l : l \neq j \rightarrow P(Y = l) * f(x|Y = l) < P(Y = j) * f(x|Y = j)$$

keine Summen mehr, identische Summanden rechts und links werden weggelassen

Übrig bleiben linke  $l$ -ter und rechts  $j$ -ter Summand

O.B.d.A.:  $k$  kann 1 gesetzt werden  $\rightarrow EK = \sum \sum p_{ij}$

Klassifizierungsregel: Muster  $x$  gegeben (Realisierung eines Experiments):

Zuordnung zur Klasse mit:

$$\text{index} \left\{ \max_{1 \leq j \leq m} \underbrace{P(Y = j) \cdot f(x|Y = j)}_{\text{Diskriminanzfunktion}} \right\}$$

Division durch  $f(\underbrace{x}_{\text{Konstante bezgl. der Index-Werte}})$

$\hookrightarrow$  Ersichtlich: Ist identisch mit Klassifikation A-posteriori-Wahrscheinlichkeiten

- **SF2:** (spezieller als SF1)

$Y$  gleichmäßig verteilt, d.h.  $\forall i P(Y = i) = \frac{1}{m}$



$$\hookrightarrow (*) \forall l : l \neq j \rightarrow f(x|Y = j) > f(x|Y = l)$$

Ist die Maximum-Likelihood-Strategie

- **SF3:** allgemeiner Fall, aber nur  $m=2$

$$EK = k_{12} \cdot P(Y = 1) \cdot \int_{G_2} f(x|Y = 1) dx + k_{21} \cdot P(Y = 2) \cdot \int_{G_1} f(x|Y = 2) dx$$

Bayes-Optimalität für  $m=2$ :

$$j = 1 \wedge x \in \text{int}(G_1) \rightarrow k_{21} \cdot P(Y = 2) \cdot f(x|Y = 2) < k_{12} \cdot P(Y = 1) \cdot f(x|Y = 1)$$

$$j = 2 \wedge x \in \text{int}(G_2) \rightarrow k_{21} \cdot P(Y = 2) \cdot f(x|Y = 2) > k_{12} \cdot P(Y = 1) \cdot f(x|Y = 1)$$

Konstruktion von  $G_1$  und  $G_2$

einfachster Fall SF2 mit  $m=2$  und mit nur einem Merkmal  $n=1$

$x$  ist bekannt. Hypothese  $H_0 : x \in K_1$ :

$p_{12}$  ist die Wahrscheinlichkeit dass  $x \in K_1$ , aber trotzdem  $x$  der Klasse 2 zugeordnet wird (wegen  $x \in G_2$ ). Das ist die Wahrscheinlichkeit für einen Fehler 1. Art.

$p_{21}$  ist die Wahrscheinlichkeit dass  $x \in K_2$ , aber trotzdem  $x$  der Klasse 1 zugeordnet wird (wegen  $x \in G_1$ ). Das ist die Wahrscheinlichkeit für einen Fehler 2. Art.

$$p_{12} = P(Y = 1) \int_{G_2} f(x|Y = 1) dx$$

Es sei zusätzlich  $k_{12} = k_{21}$

$\hookrightarrow$  Minimale Kosten, wenn die Grenze zwischen  $G_1$  und  $G_2$  durch die Lösungen von

$$(*) f(x|Y = 1) = f(x|Y = 2)$$

definiert wird.

**Bemerkung:** i.A. mehrere Lösungen, aber mindestens eine.

Bild5

- **Verallgemeinerung durch Einführung einer Rückweisungsklasse möglich**

$$\hookrightarrow \text{neuer Kostenvektor } \begin{pmatrix} k_{10} \\ k_{20} \\ \dots \\ k_{m0} \end{pmatrix}$$

$k_{i0}$  - Kosten für fälschliche Rückweisung eines Objekts einer Klasse  $K_i$

Keine Kosten  $K_{0i}$ , weil es keine echte Klasse  $K_0$  gibt, aber  $G_0$

i.A. Rückweisungskosten  $>$  Fehlklassifikations-Kosten

häufiger Spezialfall:

$$k_{0i} = k' K_{ij} = k |k'| > k, i \neq 0$$

Verallgemeinerung der Opt.-Bedingung auf Aufg. mit Rückweiseg möglich.

- **SF4:** normalverteilte Merkmalsvektoren  $X$ :

$$f(x|Y = i) = \frac{e^{-\frac{1}{2} \cdot (x-m_i)^T \cdot \text{Cov}_i^{-1} \cdot (x-m_i)}}{(2\pi)^{\frac{n}{2}} \sqrt{(\det(\text{Cov}_i))}}$$

Mit  $m_i = E(X|Y = i)$  und der bedingten Kovarianzmatrix:

$$\text{Cov}_i = E[(X' - m_i) \cdot (X' - m_i)^T]$$

$(n, m)$ -Matrix,  $X'$ -Zufallsvektor mit Dichte  $f(x|Y = i)$

Diskriminanzfunktion  $d_i(x) = f(x|Y = i) \cdot P(Y = i)$  ist zu kompliziert, deswegen:

$$\ln(d_i(x)) = -0.5 \cdot (x-m_i)^T \cdot \text{Cov}_i^{-1} \cdot (x-m_i) - \underbrace{\frac{n}{2} \cdot \ln(2\pi)}_{\text{unabhängig von i}} - 0.5 \cdot \ln(\det(\text{Cov}_i)) + \ln(P(Y = i))$$

Neue Diskriminanzfunktion (nicht unabhängig von  $i$  und mit  $-2$  multipliziert):

$$D_i(x) = (x - m_i)^T \cdot \text{Cov}_i^{-1} \cdot (x - m_i) + \ln(\det(\text{Cov}_i)) - 2 \cdot \ln(P(Y = i))$$

Klassifikationsregel: Zuordnung von  $x$  zur Klasse  $\text{index} \left\{ \min_{1 \leq i \leq m} D_i(x) \right\}$  **Bemerkung:** min wegen des Vorzeichenwechsels

**Mahalanobis-Abstand** zwischen  $x$  und  $m_i$ :  $(x - m_i)^T \cdot \text{Cov}_i^{-1} \cdot (x - m_i)$

- **SF5:** (spezieller als SF4)

$$\forall i : \text{Cov} = \text{Cov}_i, \forall i : P(Y = i) = \frac{1}{m}$$

Dann ist  $D_i(X)$  definierbar als Mahalanobis-Abstand

## BEISPIEL:

Bayes-Klassifikator zu ermitteln, der Männer und Frauen unterscheiden kann. Einziges Merkmal: Körpergröße  $X$ .

Verteilung:

$(X|Y = F) \sim N(169, 8)$ , das heißt  $m_F = 169$  und  $\delta_F = 8$

$(X|Y = M) \sim N(178, 10)$ , das heißt  $m_M = 178$  und  $\delta_M = 10$

Verwechslungskosten:  $k_{FM} = 2$  und  $k_{MF} = 1$

A-priori-Wahrscheinlichkeit:  $P(Y = F) = 0.52$  und  $P(Y = M) = 0.48$

Fehlklassifikation zu minimieren:

$$EK = k_{FM} \cdot P(Y = F) \int_{G_M} f(x|Y = F) dx + k_{MF} \cdot P(Y = M) \int_{G_F} f(x|Y = M) dx$$

Bayes-Optimalität (für 2 Klassen):

$$x \in \text{int}(G_F) \rightarrow k_{FM} * P(Y = F) * f(x|Y = F) > k_{MF} * f(x|Y = M)$$

$$2 * 0.52 * f(x|Y = F) > 1 * 0.48 * f(x|Y = M)$$

$$x \in \text{int}(G_F) \rightarrow k_{FM} \cdot P(Y = F) * f(x|Y = F) > k_{MF} \cdot P(Y = M) * f(x|Y = M)$$

$$= 2 \cdot 0.52 \cdot f(x|Y = F) > 1 \cdot 0.48 \cdot f(x|Y = M)$$

$$x \in \text{int}(G_M) \rightarrow \dots < \dots$$

zur Bestimmung von  $G_F$  und  $G_M$  ist die Gleichung:

$$\rightarrow \frac{1.04}{0.48} = \frac{f(x|Y = M)}{f(x|Y = F)} = \frac{4}{5} \cdot e^{-\frac{1}{2} \cdot \frac{(x-178)^2}{100} + \frac{1}{2} \cdot \frac{(x-169)^2}{64}}$$

Division durch  $\frac{4}{5}$ ,  $\ln$

$$-64(x - 178)^2 + 100(x - 169)^2 = 12753,0680$$

$$x_1 = 125.54 \text{ und } x_2 = 180.46$$

$\rightarrow$  wenn zwischen  $[x_1$  und  $x_2]$  dann Frau sonst Mann

Bild6

### 3.3.4 Minimax-Strategie

$F$ - Falschklassifikation (zufälliges Ereignis)

Lösung der Aufgabe:  $\max_{1 \leq k \leq m} \{P(F|Y = k)\} \rightarrow \min$

Allgemein ist Lösung schwierig.

2 Klassen-Aufgabe ist beherrschbar.  $G_1$  und  $G_2$  so gesucht dass:

$$\int_{G_2} f(x|Y = 1)dx = \int_{G_1} f(x|Y = 2)dx$$

und dabei beide Integrale minimal sind. m

Noch spezieller: nur 1 Merkmal

O.B.d.A.  $E(X|Y = 1) < E(X|Y = 2) \rightarrow f(x|Y = 1)$  und  $f(x|Y = 2)$  schneiden sich bei Stetigkeit.

$$t \text{ so zu bestimmen, dass } \int_t^\infty f(x|Y = 1)dx = \int_{-\infty}^t f(x|Y = 2)dx$$

Bild7

### 3.3.5 Neyman-Pearson-Strategie

Minimierung genau einer verwechselungs-Wahrscheinlichkeit. (auf Kosten der anderen)

Aufgabe:

$$P(F|Y = k) \rightarrow \min$$

Nebenbedingung:

$$\sum_{i=1, i \neq k}^m P(F|Y = i) \leq \alpha$$

$\alpha > 0$  ist vorgegeben

Spezialfall: 2 Klassen mit gleichen A-priori-Wahrscheinlichkeiten

$$P(F|Y = 1) = \int_{G_2} f(x|Y = 1)dx \rightarrow \min$$

$$P(F|Y = 2) = \int_{G_1} f(x|Y = 2)dx \leq \alpha$$

Das Minimum wird für  $P(F|Y = 2) = \alpha$  angenommen.

Skizze für den Spezialfall nur eines Merkmals:

Bild8

## 3.4 Texturen

### 3.4.1 Begriff, statistischer Textur-Merkmale

- **Textur** Grauwert-Strukturen, die sich aus wiederholenden, kleinen Mustern aufbauen, die intuitiv als ähnlich wahrgenommen werden.
- **Interpretation:** Texturen (als Pixelmenge) werden als Realisierung eines zufälligen Versuchs angesehen. → Ergebnis: Vektor der Grauwerte
- **Vereinbarung:**

$$\text{Grauwertmenge} = \{ \underbrace{0}_{\text{schwarz}}, 1, \dots, \underbrace{255}_{\text{weiß}} \}$$

–  $n$  - Anzahl der Pixel

–  $p_i$  - Wahrscheinlichkeit, dass ein zufällige herausgegriffenes Pixel ( gleichmäßige Verteilung,  $\frac{1}{n}$ ) den Grauwert  $i$  hat  $0 \leq i \leq 255$

–

$$h_i = \frac{\text{Anzahl der Pixel mit Grauwert } i}{n}$$

–  $h_i \approx p_i$  gilt mit hoher Wahrscheinlichkeit ( $h_i$  ist zufällige Realisierung durch vorliegendes Bild gegeben)

- $\underbrace{\{h_0, h_1, \dots, h_{255}\}}$  heißt Histogramm  
wichtiger Merkmalsvektor für die Texturen

- Gegebenfalls Grauwert-Gruppen bilden

- **Mittelwert**

$$m = \sum_{i=1}^{255} i * h_i$$

- **k-tes Moment** ( $k = 1, 2, \dots$ )

$$\mu_k = \sum_{i=1}^{255} (i - m)^k * h_i$$

- **Spezialfall**  $k = 2$

$$\text{Sreuung} == \underbrace{\delta}_{\text{Kontrastmaß}} = \sqrt{\mu_2}$$

- **Schiefe**  $\mu_3$

$\mu_3 = 0$  für symmetrische Histogramme

$\mu_3 > 0$  bei überwiegend hohen Grauwerten

$\mu_3 < 0$  bei überwiegend geringen Grauwerten

- **Glattheit**

$$g = 1 - \frac{1}{1 + \delta^2}$$

$\delta = 0 \rightarrow g = 0$  nur bei identischen Grauwerten

- **Gleichförmigkeit**

$$gf = \sum_{i=0}^{255} h_i^2$$

maximal bei identischen Grauwerten

minimal bei  $\forall i, h_i = \frac{1}{256}$

- **Entropie**

$$e = - \sum_{i=0}^{255} h_i + \log_2(h_i)$$

maximal bei identischen Häufigkeiten

in Mat-  
lab  
kann  
alles  
durch  
statx-  
ture-  
rechnet  
werden

### 3.4.2 co-occurrence Matrix

- Gegeben:
  - $(m, n)$ -Grauwertbild  $B$
  - Pixelbreite  $g(x, y)$
  - $1 \leq x \leq m$
  - $1 \leq y \leq n$
  - $k$ -Anzahl der möglichen Grauwerte ( z.B. 256)
- Gray Level Co-occurrence Matrix zweier Relationen  $R$  (  $M$ : Grauwertmatrix)
- Es sei  $R \subseteq B \times B$
- CM -  $(k, k)$ -Matrix mit folgenden Elementen:
  - $cm_{ij}$  Anzahl der Pixel-Paare  $((x_1, y_1), (x_2, y_2)) \in R$  mit  $g(x_1, y_1) = i \wedge g(x_2, y_2) = j$
  - **Achtung:** Zeilen- und Spaltenzählung von 0 an.
  - **Bemerkung:**  $R$  ist i.A. die Relation, die aus nebeneinander benachbarten Pixeln gebildet wird, also
 
$$R = \left\{ ((x_1, y_1), (x_2, y_2)) : \begin{array}{l} x_1 = x_2, y_1 = y_2 + 1 \\ 1 \leq x_i \leq m \\ 1 \leq y_i \leq n - 1 (\text{oder } n) \end{array} \right\}$$
 oder
 
$$R = \{ ((x_1, y_1), (x_2, y_2)) : x_1 = x_2, y_1 = y_2 \}$$
- **Bsp:** Grauwertbild mit 3 möglichen Werten: 0, 1, 2  
 $m = 5, n = 5$   
 $R$  - Rechts-neben-Relation  

$$B = \begin{pmatrix} 1 & 0 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 & 1 \\ 0 & 2 & 1 & 1 & 2 \\ 0 & 1 & 1 & 1 & 0 \\ 2 & 2 & 2 & 2 & 1 \end{pmatrix}$$

$$CM = \begin{pmatrix} 0 & 3 & 1 \\ 3 & 7 & 1 \\ 0 & 2 & 3 \end{pmatrix}$$
 $cm_{21} = 2$  In  $B$  steht 2 mal eine 1 rechts neben einer 2.  
 $CM$  hat die Elementesumme:  $m * (n - 1) = 5 * 4 = 20$
- Stark homogene Bereiche in  $B$   
 $\hookrightarrow$  große Werte nahe der Hauptdiagonalen in  $CM$
- starke Kontraste  $\rightarrow$  große Werte rechts oben und links unten

### 3.4.3 Textur-Modellierung

- $a_k$  - gegeben Konstanten:  $k = 1, \dots, l, a_l \neq 0$
- $Y_i$  - unkorrelierte Zufallsgrößen  $EY_i = 0$
- **Definition:** Eine Zufallsfolge, die den Gleichungen

$$X_i = \underbrace{\sum_{k=1}^l a_k X_{i-k}}_{\text{Vergangenheit}} + Y_i$$

genügt, heißt **autoregressiver Prozess** l-ter Ordnung in diskreter Zeit.

- auch 2-D-Vergangenheit denkbar

# 4 Lernen von Klassifikatoren

## 4.1 Zum Lernen-Begriff

- **Thema:** Anlernen eines Klassifikators
- Wichtig: Überprüfung der Güte
- 2 grundsätzliche Möglichkeiten:
  - optimistisches Vorgehen
  - pessimistisches Vorgehen
- **optimistisches Vorgehen**
  - Lernvorlage liege vor (Lernen mit Lehrer)
  - Belehrung eines (parameterabhängigen) Klassifikators
  - Reklassifikation
- **pessimistisches Vorgehen**
  - Zufällige Unterteilung der Gesamtprobe in :  
Lernstichprobe L (80%)  
Teststichprobe T (20%)
  - do Lernen mit Beispielen aus L:  
Reklassifikation ( L und T )  
Neudefinition von L und T)  
while(Reklassifikation klappt noch nicht  $\wedge$  noch Zeit übrig)
- **Lernbeispiel - Folgendes zu klären**
  - Was wird gelernt (z.B. Klassen)
  - Lernziel ( “optimale“ Klassen)
  - Optimalitätsbegriff ?
  - Wie wird gelernt ? ( z.B. Approximation)
  - Konvergenz gegen Lernziel gesichert ?



Beispiel: lernen eines Erwartungswertes einer Zufallsgröße  $X$

Grundlage:  $x_1, x_2, \dots, x_n$  von Umfang  $n$

$$m_n = \frac{1}{n} \sum_{i=1}^n x_i \approx EX \text{ mit hoher Wahrscheinlichkeit}$$

Hinzukommen eines neuen Wertes  $x_{n+1}$

$$m_{n+1} = \frac{n}{n+1} m_n + \frac{1}{n+1} x_{n+1}$$

## 4.2 Der Fehlerkorrektur-Algorithmus

- $S_1, S_2$  - zwei linear separierbare Stichproben
- lineare Trennfunktion ist gesucht

$$d(x) = \sum_{i=0}^m c_i x_i | x_0 = 1$$

$c_i$  und  $x_i$  sind Konstanten vektorielle Schreibweise

$$d(x) = c^T x$$

$c$  so gesucht, dass

$$c^T x = 0$$

den  $E^n$  in  $G_1$  und  $G_2$  teilt, so dass

$$c^T x > 0 \text{ für } x \in G_1, S_1 \subset G_1$$

$$c^T x < 0 \text{ für } x \in G_2, S_2 \subset G_2$$

- Es sei  $x > 0$ , dann gilt

$$c^T x = x^T c > x^T (c - \alpha x) = x^T c - \alpha x^T x$$

$$c^T x = x^T c < x^T (c - \alpha x) = x^T c + \alpha x^T x$$

$c[0]$  sei gegeben

$c[i]$  Korrekturergebnis von  $c[i-1]$

$x[i] \in S_1 \cup S_2$  wird ggf. verwendet zum korrigieren von  $c[i-1]$

Iterationsvorschrift

$$c[i+1] = c[i] \text{ falls } x[i+1] \in S_1 \wedge c[i]^T * x[i+1] > 0$$

$$c[i+1] = c[i] + \alpha x[i+1] \text{ falls } x[i+1] \in S_1 \wedge c[i]^T * x[i+1] \leq 0$$

$$c[i+1] = c[i] \text{ falls } x[i+1] \in S_2 \wedge c[i]^T * x[i+1] > 0$$

$$c[i+1] = c[i] - \alpha x[i+1] \text{ falls } x[i+1] \in S_2 \wedge c[i]^T * x[i+1] \leq 0$$

Satz: Für linear separierbare  $S_1$  und  $S_2$  gilt

$$\exists i^* \forall i \quad i \geq i^* \rightarrow c[i] = c[i+1]$$

Bemerkung:  $\alpha$  kann auch variabel gewählt werden (erst groß, dann kleiner)

abh. von  $i$

Dann muss für ein  $\epsilon > 0$  gelten

$$\forall i \quad \epsilon < \alpha[i]$$

Konvergenz in endlich vielen Schritten auch dann.

Zur Größe von  $\alpha[i]$

Es sei  $c[i]^T x[i+1] < 0$  trotz  $x[i+1] \in S_1$

$\alpha[i+1]$  soll so bemessen sein, dass

$$c[i+1]^T x[i+1] = 0$$

gilt.

Also:

$$\begin{aligned} c[i+1]^T x[i+1] &= (c[i] + \alpha[i+1] + x[i+1])^T * x[i+1] \\ \hookrightarrow \alpha[i+1] &= -\frac{c[i]^T * x[i+1]}{x[i+1]^T * x[i+1]} \end{aligned}$$

Es sei  $c[i]^T x[i+1] > 0$  trotz  $x[i+1] \in S_2$

$\alpha[i+1]$  soll so bemessen sein, dass

$$c[i+1]^T x[i+1] = 0$$

gilt.

Also:

$$\begin{aligned} c[i+1]^T x[i+1] &= (c[i] - \alpha[i+1] + x[i+1])^T * x[i+1] \\ \hookrightarrow \alpha[i+1] &= +\frac{c[i]^T * x[i+1]}{x[i+1]^T * x[i+1]} \end{aligned}$$

Das bisher falsch klassifizierte Objekt landet jetzt auf dem Rand.  
Deshalb evtl.

$$\begin{aligned} \alpha[i+1] &= \alpha[i+1] + \epsilon \\ \epsilon &\text{ klein, } \epsilon > 0 \end{aligned}$$

Bemerkungen:

1. Lineare Separierbarkeit feststellbar

## 2. Ungleichungssysteme

$$Ax \geq b$$

lösbar.

Zeilen von A als Belehrungsvektoren

Menge  $S_1, S_2 = \emptyset$

(Zeilen von A in Rolle von x

x in Rolle von c)

## 3. Trennebene i.A. nicht eindeutig

# Zum Praktikum

Programm zur Mustererkennung ( Textur oder Buchstaben )

## 4.3 statistische Klassifikation

Problem: Kenntnis bedingte Dichten

wird jetzt umgangen

Aufgabe in einfacher Form:

- Zweiklassenproblem
- Trennfunktion  $d(x)$  gesucht
- Minimierung von Fehlklassifikationen

$$d(x) = c_0 + \sum_{i=1}^n c_i f_i(x)$$

$f_i(x)$  ist vorgegebene Funktion (z.B. lineare)

Es sei  $f_0(x) \equiv 1$

c, f - Vektoren

Dann soll sein:

$$d(x) = c^T f(x) \begin{cases} > 0 & \rightarrow \text{Klasse 1} \\ < 0 & \rightarrow \text{Klasse 2} \end{cases}$$

$K(c, Y, X)$  - geg. borel-messbare Kostenfunktion, abh. u.A. von Zufallsvektor X und der zuf. Kl.-Zugehörigkeit  $Y \in \{1, 2\}$

Setze  $Z = (Y, X)^T$ , dann sei c so zu bestimmen, dass

$$E(K(c, Z)) \rightarrow \min$$

Bezeichnung der Lösung:  $c_{opt}$

Beispiel: y - Indikatorfunktion für Klassenzugehörigkeit

$$y(1) = 1 \qquad y(2) = -1$$

$$K(c, Y, X) = (\text{sign}[c^T f(X)] - y(Y)) * c^T f(x)$$

notwendige Optimierungsbedingungen:

$$\nabla_c E(K(c, Z)) = \mathbf{0}$$

analytisch nicht lösbar, wenn  $f(x|Y=i)$  nicht bekannt sind  
 $\{z[i]\}$  - Folge von Realisierungen von Z (X mit Kl.-Zugeh. - Lernen mit Lehrer)

Iterativer Ansatz für  $i \geq 0$

- a) Def. von  $c[i+1]$  in Abhängigkeit von der zufälligen i-ten Realisierung von Z  
 $(c[i+1]$  dennoch nicht zufällig wegen „E“)  
 $c[i+1] = c[i] + \alpha[i] * \nabla_c E(K(c[i], Z[i+1]))$   
 $c[0]$  sei gegeben  
 $E(K(c, Z))$  sei stetig in  $c \rightarrow \nabla_c$  und E vertauschbar  
 $c[i+1] = c[i] - \alpha[i] * E \nabla_c (K(c[i], Z[i+1]))$
- b) E ...i.A. wegen un bedingten Dichten nicht bestimmbar.  $\rightarrow$  Übergang zum statistischen Gradienten

$$C[i+1] = C[i] - \alpha[i] * \nabla_c (K(C[i], Z[i+1]))$$

Einsetzen konkreter Realisierungen  $z[i]$  für  $Z[i]$

$$c[i+1] = c[i] - \alpha[i] * \nabla_c (K(c[i], z[i+1]))$$

(Gegebenfalls zyklische Verwendung des Stichprobenmaterials)

**Satz:** Es sei

$$\sum_i \alpha[i] = \infty$$

und

$$\sum_i \alpha[i]^2 < \infty$$

Dann konvergiert die Folge  $\{ C[i] \}$  im quadratischen Mittel gegen  $c_{optimal}$ , d. h.

$$\lim_{i \rightarrow \infty} E(C[i] - c_{opt})^2$$

## 4.4 Clusteranalyse

Problemstellung: Keine vorklassifizierten Muster verfügbar. Deshalb muss man "lernen" lassen ohne Lehrer. Verschiedene mögliche Gründe wären:

- der Belehrungsaufwand ist zu hoch
- der Experte kann auch nicht klassifizieren
- keine Eindeutige Zuordnung möglich

Aufgabenstellung für Clusteranalyse:

- Untersuchung der Daten auf Struktur
- Anzahl der Klassen (ist problematisch und deswegen meists vorzugeben)
- Bestimmung des Klassifikators
- Beurteilung der Unterscheidung der Klassen

Unterscheidung von:

- statistische Clusterung
- geometrische Clusterung

**Statistische Verfahren:** - eine Idee

- wichtiges Ziel ist die bestimmung bedingter Dichten mittels Stichproben aus Grundgesamtheit mit Dichte (Ziel)

$$f(x) = \sum_{i=1}^m P(Y = i) * f(x|Y = i)$$

Stichprobe  $\underbrace{x^1, \dots, x^k}_{\text{k Vektoren der Dimensionen n}}$  vom Umfang k gegeben. Die Klassen-Zuordnung ist

hierbei unbekannt.  $f(x)$  ist zumindest empirisch bekannt. Bestimmung von  $f(x|Y = i)$  auf f nicht möglich. Deswegen treffen von Zusatz-Annahmen, wie z.B. das Normalverteilung vorliegt. Damit lassen sich die Parameter schätzen.

Annahme: Ein Parameter pro Klasse als Vektor

$$p = \begin{bmatrix} p_1 \\ \vdots \\ p_m \end{bmatrix}$$

Also:

$$f_p(x) = \sum_{i=1}^m P(Y = i) \cdot f_{p_i}(x|Y = i).$$

Bildung der Likelihood-Funktion aus einer Stichprobe vom Umfang k:

$$L_p(x_1, \dots, x_k) = \prod_{i=1}^k f_p(x^i) \text{ (i ist Index)}$$

p so wählen, dass  $L_y$  maximal wird.

$$\nabla_p * L_p = \mathbf{0}$$

Gleichungssystem lösen.

Kenntnis von von p bedeutet auch Kenntniss der  $f_{pi}(X|Y = i)$ .

Problem: Größe von  $m \rightarrow$  möglicherweise Experimente mit verschiedenen m-Werten.

## Geometrische Verfahren:

### a) Unüberwachter Min-Distanz-Algorithmus:

Suche nach Gebieten im Merkmalsraum, die Klassen entsprechen (Cluster).

Es seien unklassifizierte Stichproben gegeben:

$$\underbrace{x[1], x[2], \dots}_{\text{nD-Vektoren}}$$

Die Klassenanzahl  $m$  ist vorzugeben.

Objektbeschreibung = (  $x$ ,  $\underbrace{\text{Klassenwert}}_{\text{unbelegt}}$  )

- Festlegung von  $m$  "Zentren"  $z[j]$ , (zb. aus den  $x$ -Vektoren)
- Zuordnung von  $x$  zu dem Cluster  $C_k$ , dem es am nächsten liegt:

$$k = \underset{i \leq j \leq m}{\text{index min}} \sum_{i=1}^n (x_i - z_i[j])^2$$

- Bestimmung neuer Zentren  $z[j]$  durch:

$$z_i[j] = \frac{\sum_{l: x[l] \in C_j} x_i[l]}{\sum_{l: x[l] \in C_j} 1}, \quad \underbrace{1 \leq i \leq n}_{\text{für alle Komponenten}}, \quad \underbrace{1 \leq j \leq m}_{\text{für alle Cluster}}$$

- Wiederholung der Zuordnung zu den Clustern  $C_k$  (zurück zu Punkt 2) bis Stabilität eintritt

Probleme:

- Anzahl der Cluster, gegebenenfalls mehrer Experimente
- gute Anfangszentren
- Endzustände möglich, die kontra-Intuitiv sind

Zusatzbedingungen (Heuristiken):

- mittlerer Punkteabstand in Clustern kleiner als zwischen Clustern
- neues Cluster anlegen, wenn der Abstand zu allen Zentren zu groß ist

b) **Minimalbaum-Algorithmus:**

n Vektoren  $x[i]$  gegeben (unklassifiziert)

2 Klassen sind zu bilden

Konstruktion eines Minimalgerüsts (Baum):

Beispielbildbeschreibung:

- zufällige Punkte
- die beiden nächsten miteinander verbinden
- die vom “Strich“ am nächsten gelegene Punkt wird verbunden. ... (Verbindung wird immer nur von einem Punkt gebildet)
- wenn alle Punkte verbunden sind wird die längste Verbindung gekappt und zwei Klassen (Bäume entstehen) ... für die Anzahl der gesuchten Klassen

Programmablaufplan:

Start:

$E : n, x[j] j = 1, \dots, n$

$M = \{1, \dots, n\}$

$k \neq l$  so zu bestimmen, dass  $||x[k] - x[l]||$  minimal ist

$B = \{(x[k], x[l])\}$

$M = M \setminus \{k, l\}$

- while  $M \neq \emptyset$

- while  $(x[i], x[j])$  mit  $i \in M, j \notin M, ||x[k], x[l]||$  minimal

-  $M = M \setminus \{i\}$

-  $B = B \cup \{(x[i], x[j])\}$

\* while  $(x[s], x[t]) \in B$ , so dass  $||x[s] - x[t]||$  maximal

\*  $B = B \setminus \{(x[s], x[t])\}$

\* a: beide Teilbäume

Stop

Menge der Knoten eines Teilbaumes bilden Klasse

# 5 Merkmalsbewertung und Merkmalsauswahl

## 5.1 Motivation

ursprüngliche Merkmale: Primärmerkmale

Benutzbarkeit prüfen: zum Beispiel Gütemaße definieren

Gütemaß: Maßzahl zur Bewertung von Klassenunterscheidbarkeit auf Grund von Merkmalen (möglichst unabhängig von Klassifikator)

Merkmalselektion: gute Merkmale zur Klassifikation benutzen, schlecht nicht

### Strategien dafür

- a) Gütemaß definieren als Funktion der verwendeten Merkmale  
Weglassen von Merkmalen, die schlechtesten Beitrag für Gütemaß liefern  
Problem: hoher Aufwand
- b) Merkmalstransformation, so dass die wichtigsten und schlechtesten (transformierten, sekundären) Merkmale erkennbar werden  
Probleme: Aufwand, transformierte Merkmale i.A. nicht interpretierbar

### statistische Methoden:

- Hauptkomponentenanalyse
- Diskriminanzanalyse

## 5.2 Gütemaße

Problem: Welche Merkmale unterscheiden die Klassen besonders gut?

Idee: Maßzahl zur Unterscheidbarkeit definieren (möglichst unabhängig vom Klassifikator).

- a) Definition einer Maßzahl  
Behandlung am Beispiel der Bayes-Strategie:



also:

$$EK = \sum_{i=1}^m \sum_{j=1}^m k_{ij} \cdot p_{ij} - > Min$$

Summe aus Verwechslungskosten \* Verwechslungswahrscheinlichkeiten

$\binom{n}{k}$  Möglichkeiten, k Merkmale aus n Merkmalen auszuwählen. Theoretisch zu viele Maß-Werte berechnen. Praktisch zu viele Werte.

Voraussetzungen (wie Spezialfall 5 in 3.3.3)

$X$  ist  $n$ -dimensional und normalverteilt

$m = 2$  Klassen, keine Rückweisung

$k_{11} = k_{22} = 0, k_{12} = k_{21} = 1$

Kovarianzmatrixen:  $Cov_1 = Cov_2 = Cov$

A-priori-Klassenwahrscheinlichkeit:  $P(Y = 1) = P(Y = 2) = 0.5$

Es sei

$$L(x) = \frac{f(x|Y=1)}{f(x|Y=2)}$$

$$L^*(x) = \ln(L(x))$$

(keine Potenzzerlegung bei Normalverteilung)

$$EK = \frac{1}{2} \int_{L^*(x) \geq 0} f(x|Y=2) dx + \frac{1}{2} \int_{L^*(x) < 0} f(x|Y=1) dx$$

wird minimal, kann selbst als Gütemaß verwendet werden

Unter obigen Voraussetzungen ist:

$$L(x) \geq 1 \rightarrow x \in K_1 \leftarrow L^*(x) \geq 0$$

$$L(x) < 1 \rightarrow x \in K_2 \leftarrow L^*(x) < 0$$

Es ergibt sich mit

$$m_i = E(X|Y=i) \quad i=1,2, \text{Cov} - \text{Kovarianz-Matrix}$$

und

$$D = (m_1 - m_2)^T \cdot Cov^{-1} (m_1 - m_2)$$

$$= \sum_{i=1}^n \frac{1}{\delta_{ii}^2} (m_1[i] - m_2[i])^2$$

letzteres gilt nur bei definierten Merkmalen. Dann folgt (nach längerer Rechnung):

$$EK = \frac{1}{\sqrt{2\pi}} \int_{\sqrt{D/2}}^{\infty} e^{-Y^2/2} dY$$

EK ist eine Funktion von D. Die erwarteten Kosten sind klein wenn D groß ist. Also Merkmale so wählen, dass D maximal wird. Nun kann D als Gütemaß verwendet werden, weil EK monoton fallend sind bezüglich a

b) **Beurteilung der Klassifikationsgüte**

Zunächst wird 2-Klassen-Problem betrachtet ( $K_1, K_2$ )

$K_1$ , sei von bestimmten Interesse ("positiver" Fall)

$x_1, \dots, x_n$  - n konkrete Messwertevektoren, die klassifiziert wurden

$y_1, \dots, y_n$  - berechnete Klassen-Zugehörigkeiten

$z_1, \dots, z_n$  - tatsächliche Klassen-Zugehörigkeiten

$t_{pos}$  - Anzahl der Fälle  $y_i = z_i = 1$  ( positive, korrekte Erkennung)

$t_{neg}$  - Anzahl der Fälle  $y_i = z_i = 2$  ( negative, korrekte Erkennung)

$f_{pos}$  - Anzahl der Fälle  $y_i = 1, z_i = 2$  ( positive, falsche Erkennung)

$f_{neg}$  - Anzahl der Fälle  $y_i = 2, z_i = 1$  ( negative, falsche Erkennung)

→ (2,2)-Wahrheitsmatrix

|                 | tatsächlich positiv | tatsächlich negativ |
|-----------------|---------------------|---------------------|
| positiv erkannt | $t_{pos}$           | $f_{pos}$           |
| negativ erkannt | $f_{neg}$           | $t_{neg}$           |

| $K_1$                                | $K_2$                                |
|--------------------------------------|--------------------------------------|
| $t_{pos}$ -mal $K_1$ korrekt erkannt | $f_{neg}$ -mal $K_1$ falsch erkannt  |
| $f_{pos}$ -mal $K_2$ falsch erkannt  | $t_{neg}$ -mal $K_2$ richtig erkannt |

↔ Schätzung folgender Wahrscheinlichkeit möglich.

Richtig-positiv-Rate, Sensitivität, Trefferquote, Empfindlichkeit:

K1-Erkennung

$$P(K_1 \text{ erkannt} | K_1) \approx \frac{t_{pos}}{t_{pos} + f_{neg}}$$

Falsch-positiv-Rate:

K2-Erkennung

$$P(K_1 \text{ erkannt} | K_2) \approx \frac{f_{pos}}{t_{neg} + f_{pos}}$$

Falsch-negativ-Rate:

K1-Erkennung

$$P(K_2 \text{ erkannt} | K_1) \approx \frac{t_{neg}}{t_{pos} + f_{neg}}$$

Richtig-negativ-Rate:  
K2-Erkennung

$$P(K_2 \text{ erkannt} | K_2) \approx \frac{t_{neg}}{t_{neg} + f_{pos}}$$

Für  $n \rightarrow \infty$  "≈" fast sicher "="

P(Richtig-Erkennung)

$$\approx \frac{t_{pos} + t_{neg}}{n}$$

P(Falsch-Erkennung)

$$\approx \frac{f_{pos} + f_{neg}}{n}$$

Annahme:  $K_1$  soll keinesfalls übersehen werden. Klassifikator so gestalten, dass

$$P(K_1 \text{ erkannt} | K_1) = 1 \wedge P(K_2 \text{ erkannt} | K_1) = 0$$

↔ Zielstellung unsinnig

## 5.3 Merkmalstransformation Prüfung

X - Vektoren von Primär-Merkmalen (n-Werte)

Problem: n zu groß, Beschränkung auf k ( $k < n$ ) "wesentliche" Merkmale

↔ Transformation der Merkmale.

Bekannteste Möglichkeit: **Karhunen-Loeve-Transformation:**

A sei Orthonormalmatrix ( $n \times n$ )  $\rightarrow A^T = A^{-1}$

X sei zufälliger Merkmalsvektor, O.B.d.A. sei  $EX=0$

**Transformation:**

$$X = A \cdot Y$$

also

$$Y = A^T \cdot X$$

$a_1, a_2, \dots, a_n$  sind Spaltenvektoren von A

X soll durch Linearkombination von  $a_1, \dots, a_k$  ( $k < n$ ) ersetzt werden.

$$X = \underbrace{a_1 * Y_1 + \dots a_k * Y_k}_{\text{X soll durch die Teil-Linearkombination der Spalten von A ersetzt werden}} + a_{k+1} * Y_{k+1} + \dots a_n * Y_n$$

X soll durch die Teil-Linearkombination der Spalten von A ersetzt werden

A ist so gesucht, dass X "am besten" (im Sinne des quadrat. Mittels) approximiert wird, d.h.

Erwarteter Fehler der Approximation:

$$R_k(A) = E(X - \sum_{i=1}^k a_i \cdot Y_i)^2 = E(\sum_{i=k+1}^n a_i \cdot Y_i)^2 \rightarrow \min$$

n Nebenbedingung:  $a_i^T \cdot a_i - 1 = 0$  für alle  $i$

Diejenigen  $k$  Vektoren  $a_i$  sind auszuwählen, die im Mittel den kleinsten Approximationsfehler liefern.

$R_k(A)$  wird weiter umgeformt:

$$Y_i = a_i^T X = X^T a_i$$

und

$$\begin{aligned} (a_j \cdot Y_j)^T (a_i \cdot Y_i) &= (a_j X^T a_j)^T (a_i X^T a_i) \\ &= a_j^T \cdot X \cdot \underbrace{a_j^T \cdot a_i}_{0, \text{if } (i \neq j)} \cdot X^T \cdot a_i = \begin{cases} a_j^T X X^T a_i & \text{für } i = j \\ 0 & \text{für } i \neq j \end{cases} \end{aligned}$$

Cov - Kovarianzmatrix zu X. Muss bekannt sein, ggf schätzen (statistisches Problem)

$$R_k(A) = E(\sum_{i=k+1}^n a_i \cdot X^T \cdot a_i)^2 = \sum_{i=k+1}^n a_i^T \cdot E(X \cdot X^T) \cdot a_i = \sum_{i=k+1}^n a_i^T \cdot Cov \cdot a_i$$

$\hookrightarrow R_k(A)$  wird minimal, wenn (in diesem Fall) jeder Summand einzeln minimal wird.  
 $\hookrightarrow n-k$  gleichartige, unabhängige Optimierungsprobleme für die Summanden zu lösen.

**Zielfunktion:**

$$z_i = a_i^T \cdot Cov \cdot a_i \rightarrow \min$$

Nebenbedingung:

$$a_i^T \cdot a_i - 1 = 0$$

**Charakterisierung der Aufgabe:**

Zielfunktion und Funktion in Nebenbedingung sind beide quadratisch, also konvex.  
 eine Nebenbedingung, auch mit konvexer Funktion

$\hookrightarrow$  Methode der Lagrange-Funktion anwendbar:  $(L_i; i = 1, \dots, n)$

$$L_i(a_i) = \underbrace{a_i^T \cdot Cov \cdot a_i}_{\text{ursp. Zielfunk.}} - \underbrace{\lambda_i(a_i^T \cdot a_i - 1)}_*$$

\* Summe aus  $\mu$ -Werten, multipliziert mit NB-Funktion. Hier nur 1 Summand (nur 1 NB)

Bildung des Gradienten:

(alle partiellen Ableitungen nach den Komponenten des Vektors  $a_i$ )

$$\nabla_{a_i} L_i(a_i) = 2 \cdot Cov \cdot a_i - 2 \cdot \lambda_i \cdot a_i$$

Nullsetzen des Gradienten, Ausklammern von  $a_i$ , Einführung der Einheitsmatrix  $E$ :

$$\Leftrightarrow (Cov - \lambda_i \cdot E) \cdot a_i = 0$$

d.h. Eigenwertproblem zu  $Cov$  zu lösen  $\rightarrow \lambda_i$

$Cov$  symmetrisch  $\rightarrow$  nur reelle Eigenwerte  $Cov$  pos. semidefinit  $\rightarrow \lambda_i \geq 0$

$a_i$  sei dann Eigenvektor zu  $\underbrace{\lambda_i}_{\text{zu berechnen}} \rightarrow A$  bekannt

Zurück zum Optimierungs-Problem:

$$R_k(A) = \sum_{i=k+1}^n a_i^T \cdot Cov \cdot a_i = \sum_{i=k+1}^n a_i^T \cdot \lambda_i \cdot a_i = \sum_{i=k+1}^n \lambda_i$$

Ohne Beschränkung der Allgemeinheit soll  $\lambda_i$  fallend sortiert sein.

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k \geq \lambda_{k+1} \geq \dots \geq \lambda_n$$

$R_k(A)$  ist minimal, wenn die kleinsten  $\lambda_i$  "hinten" sind.

### Interpretation der Ergebnisse:

Spaltenvektoren der Transformationsmatrix  $A$ : orthonormierten Eigenvektoren von Kovarianzmatrix

$$Cov = EXX^T$$

"Im Mittel" beste Approximation, indem diejenigen Merkmale im Sekundärraum ausgewählt werden, die zu den  $k$  größten Eigenwerten gehören.

Berechnung Kovarianzmatrix im Sekundärraum d.h.  $Cov(Y_i, Y_j)$ :

$$\begin{aligned} E(YY^T) &= E(A^T X (A^T X)^T) \\ &= E(A^T X X^T A) \\ &= A^T \cdot E(X X^T) \cdot A \\ &= A^T \cdot Cov \cdot A \\ &= A^T \cdot E \cdot \lambda \cdot A \\ &= \text{diagMatrix}(\lambda) \text{ , alles 0, Hauptdiagonale } \lambda_i \end{aligned}$$

Diagonalmatrix mit dekorrelierten Komponenten und Varianzen ( $Var Y_i = \lambda_i$ ) in Hauptdiagonale.

Nur erste  $k$  Komponenten von  $Y$  werden zur Mustererkennung verwendet.

$\hookrightarrow$  Verwendung der ersten  $k$  Spalten von  $A$

$\hookrightarrow A_k = (a_1 a_2 \dots a_k)$

$\rightarrow Y$  jetzt  $k$ -dimensional ( nach Abschneiden der Komponenten nach Nummer  $k$ )

$$E(Y'Y'^T) = \dots = A_k^T \cdot E(XX^T) \cdot A_k$$

Varianzen  $\lambda_i$  sind Maß für die Streuung ( $\sqrt{\lambda_i}$ ) im neuen Koordinatensystem der Eigenvektoren.

Wenn  $\lambda_i = 0$ , also keine Streuung, dann kann Merkmal  $i$  (im Sekundärraum) weggelassen werden.

Falls  $\lambda_i = 0$ , gibt es keine Streuung und damit keine Information.

**Beispiel:**

$$Cov = \begin{pmatrix} 4 & 1 \\ 1 & 4 \end{pmatrix}$$

$\hookrightarrow Cov * x = \lambda * x$  zu lösen(\*)

charakteristische Gleichung:

$$\begin{vmatrix} 4 - \lambda & 1 \\ 1 & 4 - \lambda \end{vmatrix} = \lambda^2 - 8\lambda + 15 = 0$$

$$\hookrightarrow \lambda_1 = 5, \lambda_2 = 3$$

(Es soll  $\lambda_1 \geq \lambda_2$  sein)

Berechnung der Eigenvektoren (mit 1-Normierung)

Einsetzen von  $\lambda_1$  im (\*)  $\rightarrow x_1 - x_2 = 0$

Einsetzen von  $\lambda_2$  im (\*)  $\rightarrow x_1 + x_2 = 0$

Eigenvektoren:

$$e_1 = \begin{pmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{pmatrix}, e_2 = \begin{pmatrix} \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} \end{pmatrix}$$

$$A = \begin{pmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \end{pmatrix}$$

$x = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$  sei zu klassifizierender Primär-Merkmalvektor - Dimensionen 2 ( 1 zu groß)

$$y = A^T x = \begin{pmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ \sqrt{2} \end{pmatrix} \leftarrow \begin{array}{l} \text{Nach 0 wird im Sekundärraum klassifiziert} \\ \text{nicht beachten} \end{array}$$

Bemerkungen:

- a) Falls  $E(X) \neq 0$ , wird mit  $Z = X - EX$  verfahren wie beschrieben.
- b) Verfahren auch pro Klasse anwendbar, dass heißt auf einen Vektor  $X$  unter Bedingung  $Y = i$  (Klassenzugehörigkeit)  $E(X|Y = i)$  zu bilden. (Kenntnis von  $P(X \leq x|Y = i)$  erfordert, auch bedingte Kovarianzmatrizen)  
 $\hookrightarrow$  Unterschiedlichen Merkmalssätze pro Klasse möglich.
- c) Verfahren garantiert nicht erfolgreiche Klassifikation. Bild 18  
 Nach Verfahren wäre  $y_1$ -Komponente wegzulassen  $\rightarrow$  Klassen nicht mehr unterscheidbar, sonst Klassifikator muss nur  $y_1 > 0$  testen
- d) Kenntniss von Cov ist starke Voraussetzung. Praktisch muss Cov i.A. aus statischen Material geschätzt werden
- e) auch ähnliche Aufgabenstellungen denkbar:
  - Transformation soll mittleren Objektabstand pro Klasse konstant lassen
  - Transformation soll Klassenabstände maximieren

# 6 Biometrische Identifikation

## 6.1 Grundlagen

**Begriffe:** Biometrie: biologische Statistik, Zählung und Messungen von Lebewesen

Biometrik: anatomisches Messen lebenswesenspezifischer Merkmale

Biometrische Id.: Identifikation mittels Biometrik

Arten-biometrischer Id:

- Fingerabdruck
- Hand
- Gesicht
- Sprache
- Iris
- Retina
- Unterschrift
- DNA
- ...

3 Schritte:

- Auswahl der Merkmale
- Messung
- Klassifikation

Einsatz: Zugriffskontrolle, Zutrittskontrolle und Zugangskontrolle

PIN-Nachteil: keine Personengebundenheit

Eignungskriterien von Merkmalen:

- Universalität (Vorhandensein bei jeder Person)
- Einzigartigkeit (bei jeder Person anders)



- Permanenz (Zeitinvarianz)
- Erfassbarkeit

Anforderung an Verfahren:

- technische Umsetzbarkeit
- ökonomische Umsetzbarkeit
- Überlistungsresistenz

Vermutung:

Einzigartigkeit, Unveränderlichkeit

seit 1960: Entwicklung von AFIS (automated fingerprint id. system)

Fingerabdruck: Abdruck der Finger-Beere

Muster entsteht durch Papillar-Linien

Merkmale:

- Verlauf
- Breite
- Tiefe
- Gabelungen
- Linien-Enden

## 6.2 Fingerabdruck-Erkennung

- Fingerabdruck als Unterschrift im alten Indien.
- 1897 Daktyloskopie in Indien eingeführt
- 1901 England übernimmt indisches Beispiel
- 1903 Deutschland übernimmt englisches Beispiel
- seit 1960 Entwicklung von AFIS (Automated Fingerprint Identification System)
- Fingerabdruck - Abdruck der Finger-Beere (Fettpolster)
- Muster entsteht durch Papiller-Linien (Minutien)
- **Merkmale**
- Breite

- Tiefe
- Gabelungen
- Verlauf
- Linien-Enden
- **Arten von Linien-Verläufe**
- Stange
- Spirale
- Bogen
- Gabelung
- Insel
- **Forensische Verwendung**
- FA scannen → 250 kByte pro Finger
- Identifikation
- Konzentration auf benötigte Merkmale → ca. 1 kByte (damals keine FA-Rekonstruktion möglich)
- Arbeitsweise:
  - a) Bildgewinnung
  - b) Bildverarbeitung (Kontrast, Kanten, ...)
  - c) Matchen mit Referenzmustern  
(Abstandsmaße, Abstandsminimierung) mit Hilfe von Schwellenwerten
- Innerhalb der Biometrie hat die Fingerabdruckerkennung Anteil von rund 50%

## 6.3 Gesichts-Erkennungssysteme

### eine der schwierigsten Aufgaben des Erkennens

Auswertungen:

- Zugangskontrolle
- Fotodatenbanken
- Einschaffkontrolle im Auto

### 6.3.1 Gesichtssuche in einem Bild

Ziel: Gesichter und Nicht-Gesichter unterscheiden

Ist p Mittelpunkt meines Gesichtes?

dazu:

- Referenz-Gesichtsmaske über Bild schieben
- ggf. mehrfache Skalierung des Bildes
- ggf. mehrfache Rotation des Bildes
- gleiche mittlere Helligkeiten bezüglich des Bildausschnitts und Maske
- gleiche Kontraste bezüglich des Bildausschnitts und Maske

### 6.3.2 Merkmalsextraktion, Merkmalsvergleich

2 wichtige Methoden

- Eigenface-Methode
- Elastic-Graph-Matching

a) Eigenface-Methode (Turk, Pertland 1991)

Beweis: Karhunen-Loeve-Transformation

Darstellung jedes Gesichts als Linearkombination von  $n$  Referenzgesichtern im Sekundärraum. ( $m$  Koeffizienten  $\rightarrow m$  Merkmale)

Vorteil:

Gesicht wird als Ganzes gesehen.

ca.  $m = 5000$  normierte Gesichter gegeben als Vektoren (auch eine Person mehrfach)

Normalisierung: gleiche Größe und Position wichtiger Punkte (Augen, Nase, ...).

Dimensionen eines Gesichtes  $G_i$  z.B.  $n = 10000 (= 100 \times 100)$  im Raum der Gesichter

#### **Verfahren:**

Zuerst "mittleres Gesicht"  $GM$  aus dem  $G_i$  ermitteln (arithm. Mittel)

$\hookrightarrow GM$  als Ursprung des neuen Koordinatensystems.

Berechnung von  $m$  Differenzgesichtern  $G_i - GM$

Estellung einer (geschätzten)  $(n,n)$  Kovarianzmatrix:  $C = GM * GM^T$  Bestimmung der Eigenvektoren von  $C$  : gesichtsähnliches Aussehen dieser Eigenvektoren ( $\rightarrow$  Eigenfaces)

Jedes Gesicht wird dargestellt als Linearkombination der Eigengesichter

**formal:** (siehe Kapitel 5)

zufälliges Primärgesicht  $X$

Gesicht im Sekunddärraum  $Y$

orthonormale Transformationsmatrix  $A$

$$X = A * Y \rightarrow Y = A^T * X$$

$a_1, \dots, a_n$  - Spalten von  $A$

Zugehörige Eigenwerte sind Streuungsmaß in Richtung der zugehörigen Eigenvektoren.

$X$  wird ersetzt durch Linearkombination von  $a_1, \dots, a_k$  ( $k < n$ )  $Y_i$  sind die Koeffizienten der Linearkombination

$Y$  ist Bild von  $X$  im Sekunddärraum

$A$  wird aus  $C$  bestimmt

### **Gesichtserkennung:**

Transformation eines realen Gesichts im Sekunddärraum

$\leftrightarrow$  Koeffizienten repräsentieren Gesicht

Vergleich (z.B.) nach Minimum-Distanz-Prinzip

Gleichheit, falls Abstands  $\leq$  Schwellenwert, sonst Rückweisung

### **Problem:**

Auswahl "guter" Referenzgesichter schwierig

hoher, einmaliger Aufwand zur Bestimmung von  $A$

danach: akzeptabler Aufwand

### b) Elastic-Graph-Matching

Gesicht gegeben: Graph zu konstruieren

Bild mit Gesicht, in welchem Linien liegen

Funktion zu definieren, die Abstand zweier Graphen beschreibt

- Unterschiede am Knoten
- Berücksichtigung von Verzerrungen

Gleichheit  $\leftrightarrow$  Abstand  $\leq$  Schwellenwert

Verifikation verlässlich (Ist es bestimmte Person?)

Identifikation ist problematischer (Welche Person ist es?)

### **Prinzip:**

Knoten werden mit Merkmalsmengen versehen (Jets)

Verwendung als Schlüssel für Suchen im anderen Gesicht

Nutzung von Wavelets zur Berechnung der Jets

$\leftrightarrow$  Funktion für Wavelet-Transformation., geeignet zum Finden von Signalbrüchen (glänzender Punkt auf Nasenspritze)

**Wortbildung:**

onedelette (fr.) - kleine Welle  
 onde - wave (Welle)  $\hookrightarrow$  Kunstwort Wavelet

Verwendung verschiedener Graphen, verschiedenen Jets  
 konkrete Produktinfos geheim

### 6.3.3 Iriserkennung

**Vorteile:**

Invarianz gegen Stimmungen  
 Eindeutigkeit

2 Kameras

- Weitwinkel-Kameras nimmt Bild auf  
 Software sucht Gesicht und Augen
- Schwenk-Kamera mit engen Blickfeld erforscht ein Auge

**Iris-Suche:**

$K(r, x_0, y_0)$  - Kreis um  $(x_0, y_0)$  mit Radius  $r$

$g(x, y)$  - Grauwert von  $(x, y)$

**Gesucht:** die Kreislinie mit größtem Kontrastunterschied zur Umgebung  
 dazu: Maximierung der Ableitung von Kreis-Kurvenintegralen nach dem Radius

$$\max K(r, x_0, y_0) \left| \frac{\delta}{\delta r} \int_{K(r, x_0, y_0)} \frac{K(r, x_0, y_0)}{2\pi r} dr \right|$$

Gefundene Kreislinie gilt als Iris-Kontur

Kodierung der Iris-Merkmale (z.B. als 1048-Bit-String) (Downing, Daugman; 1995)

Idee zur Binarisierung:

- interessierenden iris-Bereich festlegen (z.B. untere Hälfte)
- Rasterung dieses Bereiches (z.B. 1048 Rasterpunkte)
- Mittelwert  $m$  der Grauwerte berechnen
- Zuweisung von 0 oder 1 zu jedem Rasterpunkt, je nachdem, ob sein Grauwert  $> m$  ist  
 Vergleich von 2 Irisen nach Hamming-Distanz  
 $\rightarrow$  hohe Verlässlichkeit

### 6.3.4 Sprechererkennung

Sprecherverifikation

Sprecheridentifikation

Aufzeichnungen der Schwingungen und der Mustervergleich  
sprecherspezifische Merkmale zu erheben

Verwendung von HMM (Hidden-Markow-Modelle), auch bei Schrifterkennung

**Probleme der Unterscheidung:**

- Stimmschwankungen durch Stimmungsschwankungen
- Hintergrund-Geräusche

### 6.3.5 Unterschriftenerkennung

Schriftmerkmale:

- Größe
- Neigung
- Proportionen
- Weite
- Verbundenheit
- Raumaufteilung
- Schleifenform
- Aufstriche
- mittlere Schreibgeschwindigkeit (horizontal/vertikal)
- Druckverlauf
- Variationen gleicher Buchstaben

### 6.3.6 Handrenen-Analyse

Grundlage: Infrarot-Aufnahme der Hand

## 6.4 Prüfung

Zirkel kann hilfreich sein.

### 6.4.1 Aufgabe 1

verbale Aufgabe

Grundidee und Merkmale zur Lösung liefern

### 6.4.2 Aufgabe 2

Geometrische Mittel zur Mustererkennung (einfaches Problem) Klassifikator: Minimum-distanz, nn, knn

### 6.4.3 Aufgabe 3 - x

keine Stochastische Approximation zu berechnen

aber Faktenwissen

Bayes-Klassifikator, Klassengrenzen finden und links und rechts von Grenze unterscheiden (größte Spaltensumme) Bayessches Kriterium richtig anwenden (finden der Klasse 1 und 2) 2-Klassen-Problem

Merkmalsbewertung Merkmals Auswahl Det von 3x3 Matrix bestimmen oder 2x2 Covarianz gegeben

Eigenvektoren bilden

unabhängigkeit der Eigenvektoren prüfen

Eigenwert der Covarianzmatrix  $> 0$

Verständnisfragen

Transformationsmatrix ausrechnen?