

Statistik-Skript

Hans-Christian Heinz
hheinz@imn.htwk-leipzig.de
CC-BY-NC-SA

WS2013/14

Teil I. Wahrscheinlichkeitsrechnung

1. Wahrscheinlichkeiten

1.1. Zufällige Ereignisse

Bedingungen für Experiment gegeben.

Versuch (Experiment): Realisierung der Bedingungen.

Ereignis: Ergebnis eines Experiments - soll beobachtet werden

- heißt notwendig wenn es zwingend eintritt
- heißt zufällig, wenn es eintreten kann oder nicht

1.2. Relative Häufigkeiten, Wahrscheinlichkeitsbegriff

E - Menge von zufälligen Elementarereignissen

$e \in E$ - Menge von Bedingungen, die beim Versuch realisiert werden

Ereignis A : Teilmenge von E , $A \subseteq E$

Definition: *relative Häufigkeit*

A, B Ereignisse

n Anzahl ausgeführter Experimente

k Anzahl der Experimente bei denen A beobachtet wird

$A \cap B$ das Ereignis, dass A und B beobachtet werden

$A \cup B$ das Ereignis, dass A oder B beobachtet werden

relative Häufigkeit $h_n(A) = \frac{k}{n}$

Eigenschaften von h_n

1. $0 \leq h_n(A) \leq 1$
2. $h_n(E) = 1$
3. Es sei $A \cap B = \emptyset$

$$h_n(A \cup B) = h_n(A) + h_n(B)$$

Für $n \rightarrow \infty$: $h_n(A)$ stabilisiert sich.

W Formalisierung nach Kolmogorow

MA Sigma-Mengenalgebra von Teilmengen von E , d.h. $MA \subseteq 2^E =$ Menge aller Teilmengen von E
und $E \in MA$

$$A, B \in MA \rightarrow A \cup B \in MA \wedge A \setminus B \in MA$$

$$\forall : A_i \in MA \rightarrow \bigcup_{i=1}^{\infty} A_i \in MA$$

MA soll „die interessierenden“ Ereignisse enthalten.

Bemerkung: \bar{A} von A und $A \cap B$ sind dann auch in MA

Beweis: $\bar{A} = E \setminus A, A \cap B = \overline{\bar{A} \cup \bar{B}}$

Kolmogorow'sche Axiome (1933): $P : MA \rightarrow R$ mit:

1. $\forall A : A \in MA \rightarrow P(A) \geq 0$
2. $P(E) = 1$
3. $\{A_i\}$ geg. $(A_i \in MA)$ mit $\forall i, j : i \neq j \rightarrow A_i \cap A_j = \emptyset$
Dann $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$

Definition: $[E, MA, P]$ heißt W-Raum

Beispiel:

$$E = \{e_1, e_2, \dots, e_n\}$$

$$MA \subseteq 2^E = \underbrace{\{\{\}, \{e_1\}, \dots, \{e_n\}, \{e_1, e_2\}, \dots, \overbrace{\{e_1, \dots, e_n\}}^E\}}_{2^n \text{ Elemente}}$$

p_1, p_2, \dots, p_n seien gegeben mit $\forall i : p_i \geq 0$ mit $\sum_{i=1}^n p_i = 1$

A zufälliges Ereignis

$$\hookrightarrow P(A) = \sum_{i: e_i \in A} p_i$$

Wichtiger Spezialfall: Laplace'scher W-Raum

alle Versuchsausgänge gleichwertig, d.h. $\forall i : p_i = \frac{1}{n}$

$$\hookrightarrow P(A) = \frac{\text{Anzahl der } e_i, \text{ die A bewirken}}{n}$$

Mit diesen P heißt $[E, MA, P]$ Laplace'scher W-Raum.

Wiederholung:

Ereignis und Elementarereignis

Ereignis: Ergebnis eines Experiments (im Modell: Menge von Elementarereignissen)

Elementarereignis: Satz von Bedingungen (im Modell: nicht näher bestimmt)

Warum Sigma-Mengenalgebra Zur vollständigen Erfassung (mathematischen Modellierung) von Wahrscheinlichkeiten; um auch verm. uninteressante Ereignisse zu beinhalten; damit man z.B. das Ereignis „nicht 3“ berechnen kann, indem man $1 - p(3)$ bildet
Vorlesung

1.3. Unabhängige Ereignisse

A, B (aus MA) heißen unabhängig, wenn

$$P(A \cap B) = P(A) * P(B)$$

.

A = {Professor, 7:30, pünktlich zur Vorlesung}

B = {Morgen Milchreis in der Mensa}

C = {Morgen Gewitter}

D = {Stromausfall}

rightarrow nicht modellierbar/entscheidbar Ein Ereignis ist immer stark abhängig von seinem Gegenteil!

Beispiel für Unabhängigkeit:

2 Würfel, A = {Gerade Augenzahl}, {B = Augenzahl ≥ 2 }

Insgesamt unabhängige Ereignisse

Ereignis $A : \in MA$ ($i = 1, \dots, n$) heißen insgesamt unabhängig, wenn für jede Indexmenge $\{i_1, \dots, i_k\} \subseteq \{1, \dots, b\}$ gilt:

$$P(A_{i_1} \cap \dots \cap A_{i_k}) = P(A_{i_1}) * \dots * P(A_{i_k})$$

Definition: $[E, MA, P]$ sei gegebener W-Raum

Es gelte $B \in MA$ und $P(B) > 0$

Bedingte W von A unter Bedingung B:

$$P_B(A) = P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Bemerkung: A, B unabhängig

$$\hookrightarrow P(A|B) = \frac{P(A \cap B)}{P(B)} \stackrel{!}{=} \frac{P(A) * P(B)}{P(B)} = P(A)$$

Satz: $P(A|B)$ ist eine W, d.h. gibt

(a) $\forall A \quad A \in MA \rightarrow P(A|B) > 0$

(b) $P(E|B) = 1$

(c) $P(\bigcup_{i=1}^{\infty} A_i | B) = \sum_{i=1}^{\infty} P(A_i | B)$
bei $\forall i, j \quad j \neq i \rightarrow A_i \cap A_j = \emptyset$

Beweis:

(a) $A \cap B \in MA \rightarrow P(A \cap B) \geq 0 \rightarrow \frac{P(A \cap B)}{P(B)} \geq 0$

(b) $P(E|B) = \frac{P(E \cap B)}{P(B)} = \frac{P(B)}{P(B)} = 1$

(c) $P(\bigcup_{i=1}^{\infty} A_i | B) = \frac{P([\bigcup_{i=1}^{\infty} A_i] \cap B)}{P(B)} = \frac{P([\bigcup_{i=1}^{\infty} A_i \cap B])}{P(B)}$
alle $A_i \cap B$ sind durchschnittsfremd
 $= \frac{\sum_{i=1}^{\infty} P(A_i \cap B)}{P(B)} = \sum_{i=1}^{\infty} P(A_i | B)$

Definition: $[E, MA, P_B]$ heißt bedingter W-Raum

1.4. Sätze zu bedingten Wahrscheinlichkeiten

Multiplikationssatz:

$$A_1, \dots, A_n \in MA$$

Dann gilt

$$P\left(\bigcap_{i=1}^{\infty} A_i\right) = P(A_1) * P(A_2 | A_1) * \dots * P(A_n | \bigcap_{i=1}^{\infty} A_i)$$

Beweis: $n=2$, dann vollständige Induktion

Beispiel: Urnenmodell, Kugelnziehen ohne Zurücklegen

Urne enthalte 2 weiße, 3 rote und 5 schwarze Kugeln

$A_1 = \{1. \text{ Kugel ist weiß}\}$

$A_2 = \{2. \text{ Kugel ist weiß}\}$

$A_3 = \{3. \text{ Kugel ist schwarz}\}$

$P(A_1 \cap A_2 \cap A_3)$

$= P(A_1) * P(A_2|A_1) * P(A_3|A_1 \cap A_2)$

$= \frac{1}{5} * \frac{1}{9} * \frac{5}{8} = \frac{1}{72}$

Definition: Die (unendliche) Folge $\{A_i\}$ heißt vollständiges Ereignis, wenn $\forall i A_i \in MA$
 $\forall i \forall j i \neq j \rightarrow A_i \cap A_j = \emptyset$

$\bigcup_{i=1}^{\infty} A_i = E$

E wird vollständig durch die Folge $\{A_i\}$ beschrieben

Satz von der totalen Wahrscheinlichkeit:

$A \in MA$

$\{B_i\}$ - vollständiges Ereignissystem $\forall i B \in MA; P(B_i) > 0$

Dann gilt:

$$P(A) = \sum_{i=1}^{\infty} P(A \cap B_i) = \sum_{i=1}^{\infty} P(A|B_i) * P(B_i)$$

Beweis:

$$A = A \cap E = A \cap \left(\bigcup_{i=1}^{\infty} B_i\right)$$

B_i durchschnittsfremd

$\hookrightarrow (A \cap B_i)$ auch durchschnittsfremd

Also:

$$\begin{aligned} P(A) &= \sum_{i=1}^{\infty} P(A \cap B_i) \\ &= \sum_{i=1}^{\infty} P(A|B_i) * P(B_i) \end{aligned}$$

Bsp.: 3 Urnen U_i mit schwarzen, roten, weißen Kugeln

U_1 : 3s, 3r, 2w $P(\text{Aus } U_1 \text{ wird gezogen}) = 0.3$

U_2 : 1s, 2r, 1w $P(\text{Aus } U_2 \text{ wird gezogen}) = 0.2$

U_3 : 4s, 0r, 6w $P(\text{Aus } U_3 \text{ wird gezogen}) = 0.5$

Wie groß ist W, dass eine rote Kugel gezogen wird?

$$P(r) = P(r|U_1) * P(U_1) + P(r|U_2) * P(U_2) + P(r|U_3) * P(U_3)$$

$$P(r) = \frac{3}{8} * 0.3 + \frac{1}{2} * 0.2 + \frac{0}{10} * 0.5 = \frac{17}{80}$$

Ursachensatz (Satz von Bayes)

Voraussetzungen wie zuvor

$$P(B_i|A) = \frac{P(B_i) * P(A|B_i)}{\sum_{j=1}^{\infty} P(A|B_j) * P(B_j)} \leftarrow \text{Nenner} = P(A)$$

Beweis:

$$\begin{aligned} P(B_i \cap A) &= P(A \cap B_i) \\ P(B_i|A) * P(A) &= P(A|B_i) * P(B_i) \\ P(B_i|A) &= \frac{P(A|B_i) * P(B_i)}{P(A)} \end{aligned}$$

Urnenbeispiel wie zuvor:

$$\begin{aligned} &P(U_i|r) \text{ zu berechnen} \\ P(U_1|r) &= \frac{P(U_1) * P(r|U_1)}{P(r)} = \frac{0.3 * \frac{3}{8}}{\frac{17}{80}} = \frac{9}{17} \end{aligned}$$

Lösung Übungsaufgabe vom 18.10.2013

$$\begin{aligned} P(A_1 \cap A_2) &= \frac{9}{36} = \frac{1}{4} = \frac{1}{2} * \frac{1}{2} = P(A_1) * P(A_2) \\ P(A_1 \cap A_3) &= \frac{1}{36} = \frac{1}{2} * \frac{1}{18} = P(A_1) * P(A_3) \\ P(A_2 \cap A_3) &\text{ analog} \\ P(A_1 \cap A_2 \cap A_3) &= 0 \neq P(A_1) * P(A_2) * P(A_3) \end{aligned}$$

Jeweils paarweise unabhängig, aber insgesamt nicht unabhängig

2. Zufallsgrößen (Zg)

2.1. Grundlegende Definitionen

Motivation:

X - Zg, d.h. ein Zahlenwert nach einem Experiment (noch zu präzisieren)

Von Interesse: Ereignisse

$$\{e : X(e) \leq x\}$$

$$\{e : a < X(e) < b\}$$

Definition: Mengensystem $\{(-\infty, x] | x \in \mathbb{R}\}$ wird betrachtet
 BM sei die hierdurch erzeugte Sigma-Mengenalgebra (kleinste Sigma-Mengenalgebra, die obiges Mengensystem enthält). Die Elemente von BM heißen Borel-Mengen.

Beispiele von Borel-Mengen

$$\begin{aligned} \{x : a < x \leq b\} &= \{x : x \leq b\} \setminus \{x : x \leq a\} \\ \{b\}, \text{ es sei } \{a_i\} \text{ monoton wachsend mit } \lim_{i \rightarrow \infty} a_i &= b \\ \{b\} &= \bigcap_{i=1}^{\infty} \{x : a_i < x \leq b\} \\ \{x : a < x \leq b\} \cup \{x : c < x \leq d\} \end{aligned}$$

Zg:

$[E, MA, P]$ - W-Raum

\mathbb{R} - Menge der reellen Zahlen

Es sei $B \in BM$

$X : E \rightarrow \mathbb{R}$ mit $\{e : X(e) \in B\} \in MA$

bzw. $X^{-1}(B) \in MA$


Dann heißt X eine Zg.

Bemerkungen:

Die Abbildung X heißt dann $[MA, BM]$ - messbar.

Die Messbarkeit von $[E, MA, P]$ auf $[\mathbb{R}, BM]$ übertragen

Also: Eine Zufallsgröße ist eine borel-messbare Abbildung.



Verteilungsfunktion (Vf) zu einer Zg X:

$$F(x) = P(e : X(e) \leq x)$$

$$\stackrel{\text{kurz}}{=} P(X \leq x)$$

Bemerkung: Wegen der Messbarkeit von X lässt sich zeigen, dass bei bel. $B \in BM$ gilt:

$$\{e : X(e) \in B\} \in MA$$

Also existiert $F(x)$.

Sprechweise: X ist verteilt nach $F(x)$. Oder kurz: $X \sim F(x)$.

Es gilt immer

$$\lim_{x \rightarrow -\infty} F(x) = 0$$
$$\lim_{x \rightarrow \infty} F(x) = 1$$

$F(x)$ ist monoton wachsend.

$F(x) = P(X \leq x)$ sei bekannt

$P(a < X \leq b)$ zu berechnen

$F(b) = P(X \leq b)$

$= P(\{e : X(e) \leq a\} \cup \{e : a < X(e) \leq b\})$

$= \underbrace{P(X \leq a)}_{F(a)} + P(a < X \leq b)$

$\hookrightarrow P(a < X \leq b) = F(b) - F(a)$

Definition: Verteilungsfunktion $F(x)$ gegeben, überall differenzierbar

$$f(x) = \frac{dF(x)}{dx}$$

heißt Dichtefunktion zur Zufallsgröße X .

$\hookrightarrow P(X \leq x) = \int_{-\infty}^x f(x) dx$

Definition: Zufallsgröße X, Y heißen mathematisch unabhängig, wenn

$$\forall x \forall y P(X \leq x \wedge Y \leq y) = P(X \leq x) * P(Y \leq y)$$

Bsp.: X, Y - Augenzahlen von 2 Würfeln

$Z = X + Y$, dann sind X und Z abhängig.

Körpergröße, Schuhgröße eines zufällig ausgewählten Menschen abhängig.

(Korrelation ist hinreichend, aber nicht notwendig!)

Diskrete Zufallsgröße X : X kann nur Werte annehmen aus einer Folge $\{\dots, x_{-1}, x_0, x_1, x_2, x_3, \dots\}$

Satz: Jede Verteilungsfunktion lässt sich in der Form

$$F(x) = a_1 F_1(x) + a_2 F_2(x) + a_3 F_3(x)$$

darstellen, wobei

(a) $a_i \geq 0, a_1 + a_2 + a_3 = 1$

(b) $F_1(x)$ ist absolutstetig, d.h. es gibt eine Funktion $f(x)$ mit

$$F_1(x) = \int_{-\infty}^x f(y) dy \text{ (Lebesgue Integral)}$$

Riemann-Integral ist Spezialfall des Lebesgue-Integrals
d.h.

$$F'(x) = f(x) \text{ fast überall}$$

(abgesehen von einer Menge vom Lebesgue-Maß 0)

(c) $F_2(x)$ eine diskrete Verteilungsfunktion ist (reine Sprungfunktion)

(d) $F_3(x)$ singulär ist, d.h.

$$F'(x) = 0 \text{ fast überall und stetig.}$$

2.2. Das Stieltjes-Integral

Motivation: Einf., um alle Verteilungsfunktionen einheitlich behandeln zu können. Verallgemeinerung des bekannten Riemann-Integrals.

Idee: Zu integrierende Funktion wird „gewichtet“ integriert (nicht alle x -Werte sind gleich wichtig)

Gegeben seien Funktionen $g(x)$ und $F(x)$ und ein Intervall $[a, b]$. $F(x)$ sei stetig in a , ansonsten rechtsstetig.

$g(x)$ sei stetig.

Definition: $\underbrace{Z(n, x)}_{\text{Vektor}(x_0 \dots x_n)}$ sei eine Zerlegung von $[a, b]$

folgender Art::

$$a = x_0 < x_1 < x_2 < \dots < x_n = b$$

Es sei

$$\underbrace{V(n, x)}_{\text{abhängig von } n \text{ und Vektor } x} = \sum_{i=1}^n |F(x_i) - F(x_{i-1})|$$

$$V = \sup_{Z(n, x)} \{V(n, x)\} = \text{kleinste obere Schranke bez. aller Zerlegungen von } Z(n, x)$$

V heißt totale Variation von $F(x)$ in $[a, b]$

Bsp.:

$$F = \sin x \text{ in } [0, 2\pi]$$

$$V = 4$$

Definition: des Riemann-Stieltjes-Integrals

Es sei

$$S(n, x) = \sum_{i=1}^n g(x_i) * |F(x_i) - F(x_{i-1})|$$

$$\lim_{n \rightarrow \infty} S(n, x) = \int_a^b g(x) dF(x)$$

Satz: Grenzwert eindeutig bestimmt, unabhängig von Art der Zerlegung

Uneigentliches Stieltjes-Integral

$$\int_{-\infty}^{\infty} g(x) dF(x) = \lim_{a \rightarrow -\infty} \lim_{b \rightarrow \infty} \int_a^b \dots$$

falls Grenzwert existiert.

Satz: $g(x)$ stetig und beschränkt auf $(-\infty, \infty)$

$F(x)$ von beschränkter Totalvariation auf $(-\infty, \infty)$

$\hookrightarrow \int_{-\infty}^{\infty} \dots$ ex.

Rechenregeln:

(a) Es existiere $F'(x) = \frac{dF(x)}{dx} = f(x)$

Denn

$$\begin{aligned} \int_a^b g(x) dF(x) &= \int_a^b g(x) \frac{dF(x)}{dx} dx \\ &= \int_a^b g(x) * f(x) dx \end{aligned}$$

(b)

$$\int_a^b [g_1(x) + g_2(x)] dF(x) = \int_a^b g_1(x) dF(x) + \int_a^b g_2(x) dF(x)$$

(c)

$$\int_a^b g(x) d(F_1 + F_2) = \int_a^b g(x) dF_1 + \int_a^b g(x) dF_2$$

(d) k_1, k_2 -Konst.

$$\int_a^b [k_1 * g] d[k_2 * F] = k_1 * k_2 \int_a^b g dF$$

(e)

$$\int_a^b g dF = \int_a^c \dots + \int_c^b \dots$$

(f) Partielle Integration

$$\int_a^b g(x) dF(x) = g(b) * F(b) - \int_a^b F(x) dg(x)$$

Ausblick

$g(x)$ kann abzählbar unendlich viele Unstetigkeitsstellen haben, keine fällt mit einer Unstetigkeitsstelle von $F(x)$ zusammen.

Zusammenfallen einiger Unstetigkeitsstellen \rightarrow Lebesgue-Stieltjes-Integral.

2.3. Kennwerte von Zufallsgrößen

X sei Zufallsgröße, $X \sim F(X)$

Erwartungswert:

$$EX = \int_{-\infty}^{\infty} x dF(x) \stackrel{\text{Nur bei Ex. von } f(x)}{=} \int_{-\infty}^{\infty} x * f(x) dx$$

Interpolation: Mittelwert der Versuchsausgänge

Bsp.: Würfel Verteilungsfunktion $F(x)$

$$EX = \int_{-\infty}^{\infty} x dF(x) = 1 * \frac{1}{6} + 2 * \frac{1}{6} + \dots + 6 * \frac{1}{6} = 3.5$$

Andere Schreibweise

$$EX = \int_{-\infty}^{\infty} x dF(x) = \int_E X(e) dP(de)$$

Integration über die Menge der Elementarereignisse

Regel: $a, b \in \mathbb{R} : X, Y$ Zufallsgröße

$$E(a * X + b * Y) = a * EX + b * EY$$

Varianz:

$$\begin{aligned} Var X &= E(X - EX)^2 \\ &= E(X^2 - 2 * X + EX + (EX^2)) \\ &= EX^2 - (EX)^2 \\ &= \int_{-\infty}^{\infty} (x - EX)^2 dF(x) \end{aligned}$$

a sei Konstante

$$Var(a * X) = E(a * X - a * EX)^2 = a^2 E(X - EX)^2 = a^2 * Var X$$

Streuung

$$Str X = \sqrt{Var X}$$

Beispiel: $F(x) = 0$ für $x \leq 0$; x für $x \in (0, 1]$; 1 für $x > 1$

EX , $Var X$ berechnen

Linearer Zusammenhang von Zufallsgrößen

Kovarianz:

$$Cov(X, Y) = E[(X - EX) * (Y - EY)]$$

Bemerkung 1: $Cov(X, X) = Var(X)$

Bemerkung 2: $Cov(X, Y) = E(X * Y) - EX * EY$

Korrelation:

Idee: 1-Normierung

$$Korr(X, Y) = \frac{E[(X - EX) * (Y - EY)]}{\sqrt{E(X - EX)^2 * E(Y - EY)^2}}$$

Kovarianz im Zähler, Streuung im Nenner

Satz: $-1 \leq Korr(X, Y) \leq 1$

Es gilt

$$\begin{aligned} Var(X + Y) &= E(X + Y - EX - EY)^2 \\ &= E((X - EX) + (Y - EY))^2 \\ &= E[(X - EX)^2 + 2 * (X - EX) * (Y - EY) + (Y - EY)^2] \\ &= Var X + Var Y + 2 * Cov(X, Y) \end{aligned}$$

X, Y unabhängig $\rightarrow Cov(X, Y) = 0, Korr(X, Y) = 0$

Umkehrung gilt im Allgemeinen nicht

Ausnahme: X, Y normalverteilt

Tschebyschew'sche Ungleichung

$$P(|X - EX| \geq x * Str X) \leq \frac{1}{x^2}$$

2.4. Beispiele für Verteilungsfunktion

(a) Diskrete Verteilungen

Einpunkt-Verteilungen $F(X)$

Es existiert Zahl a mit

$$\begin{aligned} P(X = a) &= 1 \\ \int_{a-0}^a x dF(x) &\stackrel{\text{Intergrand an Sprungstelle mal Sprunghöhe}}{=} a \\ &= \int_{a-0}^a (x - a) dF(x) \\ &= (a - a) * 1 = 0 \end{aligned}$$

Gleichmäßige Verteilung

n mögliche Versuchsausgänge $\{1, \dots, n\}$ alle gleichwahrscheinlich, d.h.

$$\begin{aligned} P(X = k) &= \frac{1}{n} \quad k = 1, \dots, n \\ P(X \leq k) &= \sum_{i=1}^k P(X = i) = \frac{k}{n} \\ EX &= \frac{n+1}{2} \end{aligned}$$

Binomialverteilung

Ausgangspunkt: Bernoulli'sches Schema

A gegeben ($A \in MA$) $p = P(A) > 0$

X - Anzahl des Eintretens von A bei n unabhängigen Versuchen

$$\begin{aligned} P(X = k) &= \binom{n}{k} p^k (1-p)^{n-k} \\ P(X \leq x) &= \sum_{k: k \leq x} P(X = k) \\ EX &= np \quad Var X = np(1-p) \end{aligned}$$

Geometrische Verteilung

$A \in MA$ - interessierendes Ereignis

X - Anzahl von unabhängigen Versuchen bis erstmals A eintritt

$\{X=k\}$ bedeutet: $(k-1)$ Fehlversuche A im k -ten Versuch

Geg.: $p = P(A) > 0$

$$\begin{aligned} P(X = k) &= (1-p)^{k-1} * p \text{ mit } k = 1, 2, \dots \\ \hookrightarrow EX &= \frac{1}{p} \quad Var X = \frac{1-p}{p^2} \end{aligned}$$

(b) Stetige Verteilungen

Gleichverteilung

$$F(x) = P(X \leq x) = \begin{cases} 0 & \text{für } x \leq a \\ \frac{x-a}{b-a} & \text{für } x \in (a, b] \\ 1 & \text{für } x > b \end{cases}$$

$$F'(x) = f(x) = \frac{1}{b-a} \text{ für } (a, b)$$

$$EX = \frac{a+b}{2} \quad VarX = \frac{(b-a)^2}{12}$$

Wichtiger Spezialfall: $a = 0, b = 1$

Normalverteilung

Zufallsgröße X heißt normalverteilt mit Parametern μ und σ , wenn x folg. Dichte hat:

$$nv(x, \mu, \sigma) = \frac{1}{\sigma * \sqrt{2 * \pi}} * e^{-\frac{(x-\mu)^2}{2 * \sigma^2}}$$

$$\int_{-\infty}^{\infty} nv dx = 1$$

$$NV(x, \mu, \sigma) = \int_{-\infty}^x nv(x, \mu, \sigma) dx$$

$$EX = \mu \quad VarX = \sigma^2$$

Wichtiger Spezialfall:

$$\mu = 0, \quad \sigma = 1 \quad \text{Standard-Normalverteilung}$$

Student-Verteilung (W.S. Gosset, engl. Statistiker, Pseudonym: Student)

Vorbereitung: Gamma-Funktion (Euler 1730)

$$\Gamma(x) = \int_0^{\infty} y^{x-1} * e^{-y} dy$$

Bemerkenswert: Es gilt für $x > 1$ die Funktionalgleichung

$$\Gamma(x) = (x-1) * \Gamma(x-1)$$

$$\Gamma(1) = 1, \quad \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

Für natürliches x ist das die Fakultätsfunktion $(x-1)!$

Dichte der Student-Verteilung für $x \in \mathbb{R}$ (mit n Freiheitsgraden)

$$stu(x, n) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\sqrt{\pi * n}} * \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}$$

symmetrisch bezüglich y-Achse
 $Stu(x, n)$ zugehörige Verteilungsfunktion

Satz: $\lim_{n \rightarrow \infty} Stu(x, n) = NV(x, 0, 1)$
 $X \sim Stu$
 $n \geq 2 \rightarrow EX = 0 \quad n \geq 3 \rightarrow Var X = \frac{n}{n-2}$

χ^2 -Verteilung

Dichte

$$chiQ(x, n) = \begin{cases} \frac{1}{2^{\frac{n}{2}} * \Gamma(\frac{n}{2})} * x^{\frac{n}{2}-1} * e^{-\frac{x}{2}} & , \text{ für } x > 0 \\ 0 & , \text{ für } x \leq 0 \end{cases}$$

Zugehörige Verteilungsfunktion ChiQ(x, n)

Bem. Es gibt auch χ -Verteilungen. Falls X eine χ -Verteilung hat, hat X^2 eine χ^2 -Verteilung

2.5. Simulation von Zufallsgrößen

$F(x) = P(X \leq x)$ sei bekannt.

Aufgabe: konkrete Stichprobe x_1, \dots, x_n zu erzeugen (n unabhängige Experimente mit X)

Vorüberlegung:

Y sei auf $[0, 1)$ gleichverteilte Zufallsgröße, d.h.

$$G(x) = P(Y \leq x) = x \text{ für } x \in [0, 1)$$

Satz: $F(x)$ sei stetig und streng monoton wachsend. Dann gilt für die Zufallsgröße $F^{-1}(Y)$

$$P(F^{-1}(Y) \leq x) = F(x)$$

Beweis:

$$P(F^{-1}(Y) \leq x) = P(Y \leq F(x)) = F(x)$$


Realisierungen y_i von Y sind per Zufallsgenerator erzeugbar

$F^{-1}(y_i)$ ist die i-te Realisierung von X.

Lösung obiger Aufgabe:

y_i sei erzeugt

- (a) Setze $x_i = F^{-1}(y_i)$ falls die rechte Seite existiert und eine Zahl ist.
- (b) Setze $x_i = a$, falls $F^{-1}(y_i)$ ein Intervall $[0, 1)$ ist
- (c) Setze $x_i = \min\{x : F(x) > y_i\}$, falls $F^{-1}(y_i)$ nicht existiert.



Beispiel: Würfel-Verteilungsfunktion

(b) Es sei $y_i = 0.5$
 $F^{-1}(y_i) = F^{-1}(0.5) = [3, 4)$
 $\hookrightarrow x_i = 3$

(c) Es sei $y_i = 0.51$
 $\min x : F(x) > 0.51 = 4$

2.6. Quantile


Zufallsgröße X , $x \sim F(x)$

Es sei $0 \leq p \leq 1$. Jede Zahl Q_p , die der Bedingung

$$F(Q_p - 0) \leq p \leq F(Q_p)$$

genügt, heißt p -Quantil von $F(x)$.

0.5-Quantile heißen Mediane.



Für Würfel-Verteilungsfunktion: 0.4-Quantil ist genau die 3, 0.45-Quantil auch.

Jede Zahl aus $[3, 4]$ ist Median, insbesondere auch die 4.

Bemerkung: $F(X)$ ist streng monoton \rightarrow alle Quantile eindeutig.

3. Funktionen von Zufallsgrößen und Zufallsvektoren

3.1. Funktionen einer einzelnen Zufallsgröße

Gegeben: W-Raum $[E, MA, P]$, Zg X , Funktion $g(x)$

Bilde $g(X)$. Laut Zufallsgrößen-Definition müsste $g(X(e))$ borel-messbar sein. X selbst ist borel-messbar. X bildet Ereignisse $A \in MA$ in Sigma-Mengen algebra BM ab.

Definition: $g(x)$ heißt borel-messbar, wenn für jedes $B \in BM$ gilt:

$$g^{-1}(B) \in BM$$

Satz: Ist die Funktion $g(x)$ stückweise stetig, dann ist sie borel-messbar.

Beispiel: Quadrat einer Zufallsgröße

X sei positive Zufallsgröße $X \sim F(x)$

$$P(X^2 \leq x) = P(X \leq \sqrt{x}) = F(\sqrt{x})$$

3.2. Zufallsvektoren

Borel-Messbarkeit ist auf Funktionen mehrerer Variabler übertragbar.

Folgende Funktionen sind borel-messbar:

- Vielfache
- Summen
- Produkte
- Quotienten (falls def.)
- Maximum, Minima
- Infikatorfunktionen
- Grenzwerte von Folgen einer Zufallsgröße

Definition: X_1, \dots, X_n -Zufallsgröße über $[E, \mathcal{M}, P]$

$$F(x_1, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n)$$

heißt gemeinsame Verteilungsfunktion der Zufallsgröße.


Die $P(X_i \leq x_i)$ heißen Randverteilungen.

F monoton wachsend bezüglich jedes x:

$$n = 2 \quad P(X \leq x, Y \leq y) \rightarrow P(X \leq x) = \lim_{y \rightarrow \infty} P(X \leq x, Y \leq y)$$

Berechnung von

$$\begin{aligned} &P(a < X \leq b, c < Y \leq d) \\ &= \underbrace{F(b, d) - F(b, c) - F(a, d) + F(a, c)}_{\geq 0, \text{ sonst ist F keine Verteilungsfunktion}} \end{aligned}$$



Definition:

$$f(x_1, \dots, x_n) = \frac{\delta^n F(x_1, \dots, x_n)}{\delta x_1 \dots \delta x_n}$$

heißt Dichtefunktion von $\begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}$, wenn die Ableitungen existieren und stetig sind (Voraussetzung des Satzes von Schwarz).

Definition: (Fall $n=2$, leicht verallgemeinerbar)

Gegeben: Zufallsgrößen X, Y : $X \sim F_X(x)$ $Y \sim F_Y(y)$

$$F_X(x|y) = P(X \leq x | Y = y) = \lim_{h \rightarrow 0} \frac{P(X \leq x, y - h < Y \leq y + h)}{P(y - h < Y \leq y + h)}$$

heißt bedingte Verteilungsfunktion von X unter der Bedingung Y=y, falls der Limes existiert.

Definition:

$$E(X|Y = y) = \int_{-\infty}^{\infty} x dF_X(x)$$

heißt bedingter Erwartungswert unter Bedingung Y=y, falls Integral existiert.

Formeln für bedingte Dichten/bedingte Wahrscheinlichkeits-Verteilungen (diskreter Fall)
→ Literatur.

n-dimensionale Normalverteilung:

Zufallsvektor $X = \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}$ gegeben.

X_i nicht einpunktverteilt

Erwartungsvektor $EX = \begin{pmatrix} EX_1 \\ \vdots \\ EX_n \end{pmatrix}$ und die Kovarianzmatrix C seien bekannt.

$$EX = \begin{pmatrix} EX_1 \\ \vdots \\ EX_n \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_n \end{pmatrix}$$

$$C = \begin{pmatrix} Var(X_1) & Cov(X_1, X_2) & \dots & Cov(X_1, X_n) \\ Cov(X_1, X_2) & Var(X_2) & \dots & Cov(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(X_1, X_n) & \dots & \dots & Var(X_n) \end{pmatrix}$$

C ist symmetrisch und positiv definit → C^{-1} existiert

X heißt normalverteilter Zufallsvektor, wenn er folgende Dichtefunktion hat:

$$nv(x, \mu, X) = \frac{1}{\sqrt{(2\pi)^n * det(c)}} * e^{-\frac{(x-\mu)^T * C^{-1} * (x-\mu)}{2}}$$

3.3. Funktionen von Zufallsvektoren

Beispiel: Summe zweier Zufallsgrößen X und Y.

$\{y_i\}$ sei eine Zerlegung der y-Achse

$$\dots y_{-1} < y_{-1} < y_0 < y_1 < y_2 < \dots$$

$$P(X + Y \leq y) = \sum_{i=-\infty}^{\infty} P(X + Y | Y \in (y_i, y_{i+1}]) * \overbrace{P(Y \in (y_i, y_{i+1}])}^{F_Y(y_{i+1}) - F_Y(y_i)}$$

Zerlegungsverfeinerung, Integral-Längen gegen 0:

$$= \int_{-\infty}^{\infty} P(X \leq x - y | Y = y) dP(Y \leq y)$$

falls X, Y unabhängig:

$$= \int_{-\infty}^{\infty} F_X(x - y) dF_Y(y)$$

Faltungsintegral $\xrightarrow{\text{falls Existenz der Dichten}}$ $f_{x+y}(x) = \int_{-\infty}^{\infty} f_x(x - y) * f_y(y) dy$

4. Grenzwertsätze - die Brücke zur Statistik

4.1. Konvergenzbegriffe für Folgen von Zufallsgrößen

W-Raum $[E, \mathcal{M}, P]$ gegeben; X, Y, X_1, X_2, \dots - Zufallsgrößen

E - sicheres Ereignis

\emptyset - unmögliches Ereignis: $P(\emptyset) = 0$

$A \in \mathcal{M}$ heißt fast sicher, wenn $P(A) = 1$

\mathcal{M} heißt fast unmöglich, wenn $P(A) = 0$

X, Y heißen gleich, wenn $\forall e \in E \rightarrow X(e) = Y(e)$

X, Y heißen fast sicher gleich, wenn $P(e : X(e) = Y(e)) = 1$

Stochastische Konvergenz (auch „Konvergenz in Wahrscheinlichkeit“): Eine Folge $\{X_i\}$ von Zufallsgrößen konvergiert stochastisch gegen die Zufallsgröße X , wenn

$$\forall \epsilon_1 \forall \epsilon_2 \exists n_o(\epsilon_1, \epsilon_2) \forall n(\epsilon_1 > 0 \wedge \epsilon_2 > 0 \wedge n \geq n_o \rightarrow P(e : |X_n(e) - X(e)| \geq \epsilon_1) \leq \epsilon_2)$$

kurz:

$$\epsilon > 0 \rightarrow \lim_{n \rightarrow \infty} P(|X_n - X| \geq \epsilon) = 0$$

$$\{x_n\}^P \rightarrow X$$

Fast sichere Konvergenz

$$P(e : \lim_{n \rightarrow \infty} X_n(e) = X(e)) = 1$$

kurz:

$$\{X_n\} \xrightarrow{\text{f.s.}} X$$

Interpretation: Es ist fast sicher, dass für wachsendes n X_n ein letztes Mal stark von X abweicht (mehr als ϵ), danach nie wieder.

(Es ist im Grunde klassische Konvergenz für die meisten ϵ - aber eben nicht für alle.)

Konvergenz im quadratischen Mittel

EX^2 möge existieren

$$\lim_{n \rightarrow \infty} E(X_n - X)^2 = 0$$

Konvergiert den Verteilungen nach (schwache Konvergenz)

$$X \sim F(x), X_n \sim F_n(x)$$

$\{x_n\}$ konvergiert schwach gegen X , wenn

$$\forall x (F \text{ stetig an Stelle } x) \rightarrow \lim_{n \rightarrow \infty} F_n(x) = F(x)$$

Satz: Fast sichere Konvergenz \rightarrow stochastische Konvergenz
stochastische Konvergenz \rightarrow schwache Konvergenz

4.2. Gesetze der großen Zahlen

Zum Begriff

$\{x_i\}$ - Folge von Zufallsgrößen. Es sei

$$z_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Gegenstand ist das Konvergenzverhalten der Folge $\{z_n\}$

Definition: $\{x_i\}$ genügt den schwachen GGZ, wenn Konstante a existiert mit:

$$\{z_n\} \xrightarrow{P} a$$

Definition: $\{x_i\}$ genügt den starken GGZ, wenn Konstante a existiert mit:

$$\{z_n\} \xrightarrow{\text{f.s.}} a$$

Die GGZ sind Grundlage vieler Resultate der Statistik.

Gefragt sind notwendige und hinreichende Bedingungen, insbesondere für starkes GGZ.

Spezialfall:

Alle X_i insgesamt unabhängig und identisch verteilt. \rightarrow wichtige Resultate bekannt.

Relative Häufigkeit

n - Anzahl von Experimenten

k - Anzahl der Experimente, bei denen A beobachtet wurde

$h_n(A)$ wird mit Hilfe von Zufallsgrößen definiert:

$$X_i = \begin{cases} 0 & \bar{A} \text{ im } i\text{-ten Versuch} \\ 1 & A \text{ im } i\text{-ten Versuch} \end{cases} \quad h_n(A) = \frac{\sum_{i=1}^n X_i}{n}$$

Satz von Bernoulli (Jakob, 1654-1705)

$\epsilon > 0$ beliebig, $p = P(A)$. Dann gilt

$$\lim_{n \rightarrow \infty} P(|h_n(A) - p| < \epsilon) = 1$$

D.h. $\{h_n(A)\} \xrightarrow{P} p$ (stochastische Konvergenz)

\sim genügt dem schwachen GGZ.

Satz von Borel(1909)

$$\{h_n(A)\} \xrightarrow{f.s.} p$$

Beweis mit Hilfe des Satzes von Kolmogorow

$$\forall i \quad EX_i = P(A) * 1 + (1 - P(A)) * 0 = P(A) = p$$

d.h. für alle Summanden in $h_n(A)$

$$\hookrightarrow Eh_n(A) = \frac{n * p}{n} = p$$

4.3. Der Zentrale Grenzwertsatz (ZGS)

Definition: Wenn eine Summe von Zufallsgrößen (z.B. arithmetische Mittel) asymptotisch normalverteilt ist, sagt man: „Es gilt der ZGS“. (Das ist in vielen Fällen so.)

Satz von Lindeberg-Lévy

$\{x_i\}$ - Folge von insgesamt unabhängigen, identisch verteilten Zufallsgrößen mit endlicher Varianz.

Es sei

$$Y_n = \sum_{i=1}^n X_i \text{ und } \mu = EX_1 \quad \sigma^2 = Var X_1 \neq 0$$

Es gilt $EY_n = n * \mu$ und wegen der Unabhängigkeit $Var Y_n = n * \sigma^2$

Für die Zufallsgröße

$$z_n = \frac{Y_n - n * \mu}{\sigma * \sqrt{n}} = \frac{\frac{Y_n}{n} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

$\frac{Y_n}{n}$ - arithmetisches Mittel

$\mu - E\left(\frac{Y_n}{n}\right)$

$\frac{\sigma}{\sqrt{n}} - Str\left(\frac{Y_n}{n}\right)$

Mit der Verteilungsfunktion $F_n(x) = P(Z_n \leq x)$ gilt dann $EZ_n = 0$

Satz von Lindeberg-Lévy: Es gilt der ZGS, insbesondere

$$\lim_{n \rightarrow \infty} F_n(x) = \int_{-\infty}^x nv(y, 0, 1)dy = \frac{1}{\sigma * \pi} * \int_0^x e^{-\frac{y^2}{2}} dy$$

Sprechweise: $\{Z_n\}$ ist asymptotisch normalverteilt.

Zusatz:

Existiert $E|X_i|^3$, ist die Konvergenz sogar gleichmäßig.

Folgerung: n sei groß $\rightarrow P(a < Z_n \leq b) \approx \frac{1}{2\pi} \int_a^b e^{-\frac{y^2}{2}} dy$

Bemerkung: Y_n ist als Summe darstellbar. A sei interessierendes Ereignis mit $P(A) = p$.

X sei folgende Zufallsgröße:

$$X = \begin{cases} 1 & \text{falls } A \text{ eintritt} \\ 0 & \text{sonst} \end{cases}$$

$$\hookrightarrow EX = p, Var X = EX^2 - (EX)^2$$

$$= p - p^2 = p(1 - p)$$

Mit X werden n Versuche gemacht $\rightarrow x_1, \dots, x_n$

$$\text{Dann ist } Y_1 = \sum_{i=1}^n X_i$$

Für die Zufallsgröße

$$Z_n = \frac{\overbrace{Y_1 - n * p}^{EY_n}}{\underbrace{\sqrt{n * p * (1 - p)}}_{StrY_n}}$$

gilt dann wieder $EZ_n = 0, Var Z_n = 1$.

Satz von Moivre-Laplace:

Die Zufallsgröße Z_n sind asymptotisch standardnormalverteilt:

$$\lim_{n \rightarrow \infty} P(Z_n \leq x) = NV(x, 0, 1)$$

Für große n gilt

$$P(a < Z_n \leq b) \approx \frac{1}{2\pi} \int_a^b e^{-\frac{y^2}{2}} dy$$

$$= P(a * \sqrt{n * p * (1 - p)} + n * p < Y_n \leq b * \sqrt{n * p * (1 - p)} + n * p)$$

Für ausreichend gute Näherungen sollte gelten

$$n * p * (1 - p) > 9$$

d.h.

$$n > 36 \text{ bei } p = 0.5$$

Beispiel:

Integralberechnung nach Monte-Carlo-Methode

Motivation: Methode für zahlreiche best. Integrale anwendbar.

Aufgabe:

$$I = \int_0^\pi \sin x dx \quad (= 2, \text{ Erg. bekannt})$$

Ansatz: Der Kurvenverlauf wird in ein Rechteck eingehüllt. Fläche des Rechtecks = π .
 Es werden n über Rechteck gleichverteilte Punkte (X_i, Y_i) in das Rechteck „geworfen“.
 Voraussetzung:

Versuche insgesamt unabhängig,

$\forall i : X_i, Y_i$ unabhängig,

$X_i \sim [0, \pi]$ - Gleichverteilung

$Y_i \sim [0, 1]$ - Gleichverteilung

Es sei $A = \{e : Y_i \leq \sin(X_i)\}$

$$p = P(A) = \int_0^\pi \int_0^{\sin x} \frac{1}{\pi} dy dx = \frac{2}{\pi} = 0.636620$$

$a_n(A)$ - absolute Häufigkeit der Punkte, die nicht oberhalb des Graphen von $\sin x$ in $[0, \pi]$ liegen.

$h_n(A) = \frac{a_n(A)}{n}$ - relative Häufigkeit p wird geschätzt durch $h_n(A)$. Beispiel-Daten:

$n = 1000$, davon

$a_n(A) = 6377$ Punkte oberhalb von $\sin x$

$h_n(A) = 0.6377$

I wird geschätzt als Teilfläche 63.77% der Gesamtfläche vom Rechteck der Größe π :
 $I \approx 0.6377 * \pi = 2.000252$

Problem: Abweichung des „wahren“ p -Wertes von der zufälligen Realisierung $h_n(A) = 0.6377$.

Abschätzung der Genauigkeit

Für die absolute Häufigkeit $a_n(A) = h_n(A) * n$ gilt nach dem Satz von Moivre-Laplace, dass

$$Z_n = \frac{a_n(A) - n * p}{\sqrt{n * p * (1 - p)}} = \frac{(h_n(A) - p) \sqrt{n}}{\sqrt{p * (1 - p)}}$$

asymptotisch normalverteilt ist.

Für $n=10000$ liegt NV praktisch vor.

Zufallsgröße $Z \sim NV(x, 0, 1)$; $t > 0$ wird so bestimmt, dass

$$P(-t < Z \leq t) = \frac{1}{\sqrt{2\pi}} \int_{-t}^t e^{-\frac{y^2}{2}} dy = 0.95$$

Lösung: $t = 1.96$ (geringfügig zu groß)

Es gilt sogar $P(-1.96 < Z \leq 1.96) > 0.95$

$\hookrightarrow P(-1.96 < Z_n \leq 1.96) > 0.95$
n groß

Frage 1: Wie genau wird p durch $h_n(A)$ approximiert?

$$\begin{aligned} 0.95 &< P(-t < Z_n \leq t) \\ &= P(|h_n(A) - p| \leq t * \frac{\sqrt{p(1-p)}}{\sqrt{n}}) \end{aligned}$$

$$\begin{aligned}
&< P(|h_n(A) - p| \leq \frac{1}{2 * \sqrt{n}}) \quad |t = 1.96 \\
&= P(\sim \leq \frac{0.98}{\sqrt{n}}) \\
&< P(|h_n - p| \leq \frac{1}{\sqrt{n}})
\end{aligned}$$

Frage 2: Welche Werte kommen für p in Frage, so dass $-t < Z_n \leq t$ gilt?
Dazu: Lösung der Gleichungen $Z_n = \pm t$ (für $a_n(A) = 6377$)

$$\begin{aligned}
&\frac{a_n(A) - n * p}{\sqrt{n * p * (1 - p)}} = \pm t \\
&(a_n(A) - n * p)^2 = n * p * (1 - p) * t^2 \\
&\hookrightarrow p^2 - \frac{2 * a_n(A) + t^2}{n + t^2} * p + \frac{a_n(A)^2}{n^2 + n * t^2} = 0 \\
&p_1 = \frac{2 * a_n(A) + t^2}{2 * (n + t^2)} \sqrt{\frac{2a_n(A) + t^2}{2 * (n + t^2)} - \frac{a_n(A)^2}{n^2 + n * t^2}} \\
&p_2 = \sim + \sim
\end{aligned}$$

Einsetzen obiger Beispiel-Daten:

$$n = 10000$$

$$a_n(A) = 6377$$

$$t = 1.96$$

$$\hookrightarrow p_1 = 0.628228$$

$$\hookrightarrow p_2 = 0.647066$$

Für p-Werte aus $[p_1, p_2]$ ist das Versuchsergebnis plausibel

$$\hookrightarrow 1.973636 = \pi * p_1 < \int_0^\pi \sin x dx \leq \pi * p_2 = 2.032817$$

verlässlich mit 0.95 Sicherheit.

4.4. Die empirische Verteilungsfunktion

Gegeben: die Zufallsgröße $X \approx F(x)$, $F(x)$ stetig

Ausführung von n insgesamt unabhängigen Versuchen mit X

$$\hookrightarrow X_1, \dots, X_n \quad X_i \approx F(x)$$

$$I(X_i, x) = \begin{cases} 1 & , \text{ wenn } X_i > x \\ 0 & \text{ sonst} \end{cases}$$

Empirische Verteilungsfunktion zu F(x)

$$Emp_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i, x)$$

Satz von Gliwenko (Hauptsatz der mathematischen Statistik)
 $\epsilon > 0$ beliebig gegeben. Dann gilt für die Zufallsgrößen-Folge $\{D_n\}$ mit

$$D_n = \sup_{x \in \mathbb{R}} |Emp_n(x) - F(x)|$$

$$P(\lim_{n \rightarrow \infty} D_n \leq \epsilon) = 1$$

Bemerkung: Satz rechtfertigt, $Emp_n(x)$ als Ersatz für $F(x)$ zu benutzen, falls $F(x)$ unbekannt (n möglichst groß)

Satz von Kolmogorow:

Bei stetigem $F(x)$ gilt:

$$K(x) = \lim_{n \rightarrow \infty} P(\sqrt{n} * D_n \leq x) = \begin{cases} 0 & \text{für } x \leq 0 \\ 1 + 2 * \sum_{i=1}^{\infty} (-1)^i * e^{-2i^2 x^2} & \text{für } x > 0 \end{cases}$$

Bemerkung: Satz ist theoretische Grundlage für Kolmogorow-Anpassungstest

Teil II.

Statistik

1. Grundlegende Begriffe der Statistik

Gegenstand: Wahrscheinlichkeits-Aussagen

- ohne Kenntnisse der Verteilungsfunktion
- mit Kenntnissen von Stichproben

Grundgesamtheit:

Gegeben:

- W-Raum $[E, MA, P]$
- der messbare Raum $[R, BM]$
- Zufallsgröße $X: E \rightarrow R$
- $F_X(x) = P(e : X(e) \leq x)$
- W-Raum $[R, BM, F_X(x)]$

$[R, BM, F_X]$ heißt Grundgesamtheit mit Verteilung F_X

X - Zufallsgröße, $F_X(x)$ unbekannt (im Allgemeinen)

n unabhängige Experimente mit X liefern Realisierungen x_1, \dots, x_n

$\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$ heißt konkrete Stichprobe von X aus der Grundgesamtheit

X_1, \dots, X_n - insgesamt unabhängige Zufallsgrößen mit Verteilungsfunktion $F_X(x)$ (Vorstellung: n gedachte Experimente)

$\begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}$ heißt mathematische Stichprobe

Beschreibende Statistik:

Wiedergabe vorhandener Daten durch Auswahl und geeignete Darstellung mit Bestimmung interessierender Kenngrößen

(Diagramme, Häufigkeitstabellen, Mittelwerte, ...)

Schließende Statistik:

Mathematische Auswertung gezielt erhobener Stichproben, Rückschlüsse auf die Grundgesamtheit

Typische Aufgabenstellungen

Punktschätzungen:

- W
- EX
- $\text{Str}X, \text{Var}X$
- Parameter von $F(x)$
- ...

Aussagen über Verlässlichkeit

Berechnung von Irrtumswahrscheinlichkeiten

Intervallschätzungen:

Schätzung eines Intervalls in das die Punktschätzung fällt mit Wahrscheinlichkeit, dass das auch geschieht.

Hypothesentests:

Ist Stichprobe mit Hypothese über Grundgesamtheit verträglich?

Stichproben-Funktion:

ist eine borel-messbare Funktion $g(x_1, \dots, x_n)$

$\hookrightarrow (X_1, \dots, X_n)$ ist dann Zufallsgröße

2. Schätztheorie

2.1. Punktschätzungen - grundlegende Definitionen

Zwei einführende Beispiele: Zufallsgröße $X \sim F(x)$ gegeben
i.A. unbekannt

EX wird geschätzt durch die Zugfallsgröße

$$M_n = \frac{1}{n} \sum_{i=1}^n X_i$$

X_i : Ergebnis von n Experimenten mit X

Einsetzen einer konkreten Stichprobe $\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$

$$\hookrightarrow m_n = \frac{1}{n} \sum_{i=1}^n x_i \approx EX$$

$\text{Var}X$ wird geschätzt durch

$$V_n = \frac{1}{n-1} \sum_{i=1}^n (X_i - M_n)^2$$

empirische Varianz

v_n - Realisierung von V_n :

$$v_n = \frac{1}{n-1} (x_i - m_n)^2 \approx \text{Var}X$$

Interessant: Untersuchung der Verteilungsfunktion von M_n und V_n

Bemerkung: $M_n \sim F^{n*}(n * x)$

F^{n*} ist n -fache Faltung von $F(x)$ mit sich selbst.

$P(A)$ wird geschätzt durch $h_n(A)$
Spezialfall von m_n

Verallgemeinerung

t sei ein unbekannter Parameter der Verteilungsfunktion $F_X(x)$, also $t = t(F_X)$

t sei zu schätzen: $t \in D$ (Wertebereich)

Bemerkung: t kann ein Vektor sein

Die Menge der in Frage kommenden Verteilungsfunktionen kann eingeschränkt sein (Beispiel: „Familie“ der Normalverteilungen; $t = \begin{pmatrix} \mu \\ \sigma \end{pmatrix}$)

Häufige Voraussetzungen:

X_1, \dots, X_n - insgesamt unabhängig Exemplare von X

$(x_1, \dots, x_n)^T$ - konkrete Stichprobe

g - borel-messbare Funktion: n -stellig

Die Stichprobenfunktion $g(X_1, \dots, X_n)$ heißt Schätzfunktion bzw. eine Punktschätzung für („den Punkt“) t .

$g(x_1, \dots, x_n)$ wird als Ersatz für t benutzt.

Aber mit welchem Grund?

g sollte wünschenswerte Eigenschaften haben:

Erwartungstreue: g heißt erwartungstreu, wenn

$$\forall F_X \quad E g(X_1, \dots, X_n) = t(F_X) \quad \text{mit } \forall i \, X_i \sim F_x$$

Eine Folge $\{g_n\}$ von Schätzfunktionen heißt asymptotisch erwartungstreu, wenn

$$\forall F_X \quad \lim_{n \rightarrow \infty} E g_n = t(F_X)$$

Systematischer Fehler (Synonyme: Verzerrung, Bias)

$$E g(X_1, \dots, X_n) - t(F_X) \text{ (i.a. ein Vektor)}$$

Meist systematischer Fehler von g gegenüber t . Bemerkung; Erwartungstreue Schätzfunktionen sind biasfrei

Konsistenz: $\{g_n\}$ heißt schwach/stark konsistent, wenn $\{g_n\} \xrightarrow{P/f.s.} t(F_X)$

Bessere Schätzfunktion

g_1 heißt besser als g_2 , wenn für alle $\epsilon > 0$ und alle $t \in D$ gilt:

$$P(|g_1(X_1, \dots, X_n) - t| \leq \epsilon) > P(|g_2(\dots) - t| \leq \epsilon)$$

Wirksamere Schätzfunktion:

g_1, g_2 - erwartungstreu bezüglich t

g_1 heißt wirksamer als g_2 , wenn für $t \in D$

$$Var[g_1(X_1, \dots, X_n)] < Var[g_2(X_1, \dots, X_n)]$$

Wirksamste Funktion ...

2.2. Punktschätzungen - wichtige Sätze

Satz: Hinreichend für schwache Konsistenz sind

- asymptotische Erwartungstreue
- $\lim_{n \rightarrow \infty} Var[g_n(X_1, \dots, X_n)] = 0$

Satz: M_n ist erwartungstreu für EX. Beweis trivial.

Satz: $X, X_i \sim F(X)$ X_i insgesamt unabhängig

$$V_n = \frac{1}{n-1} \sum_{i=1}^n (X_i - M_n)^2 \quad S_n = \sqrt{V_n} (\approx \text{Str} X)$$

Behauptung: V_n schätzt $\text{Var} X$ erwartungstreu.

Beweis: Zuerst Umschreiben von V_n - Klammern ausmultiplizieren

$$\begin{aligned} V_n &= \frac{1}{n-1} \sum_{i=1}^n (X_i^2 - 2 * X_i * M_n + M_n^2) \\ V_n &= \frac{1}{n-1} \sum_{i=1}^n X_i^2 + \frac{1}{n-1} (-2 * M_n * \sum_{i=1}^n X_i + \sum_{i=1}^n M_n^2) \\ V_n &= \frac{1}{n-1} \sum_{i=1}^n X_i^2 + \frac{1}{n-1} (-2 * M_n * n * M_n + n * M_n^2) \\ V_n &= \frac{1}{n-1} \sum_{i=1}^n X_i^2 - \frac{n}{n-1} M_n^2 \end{aligned}$$

Erwartungswertbildung (X_i durch X ersetzbar, \sum entfällt)

$$EV_n = \frac{n}{n-1} (EX^2 - EM_n^2)$$

Hier fehlt ein Stück!

Damit folgt:

$$\begin{aligned} EV_n &= \frac{n}{n-1} * [E(X^2) - \frac{1}{n} E(X^2) - \frac{n-1}{n} (EX)^2] \\ &= \frac{n}{n-1} * (\frac{n-1}{n} E(X^2) - \frac{n-1}{n} (EX)^2) \\ &= EX^2 - (EX)^2 = \text{Var} X \end{aligned}$$

Bemerkungen

(a) Wäre EX bekannt, könnte $\text{Var} X$ durch

$$W_n = \frac{1}{n} \sum_{i=1}^n (X_i - EX)^2$$

erwartungstreu geschätzt werden

(b) Mit

$$V_n = \frac{1}{n} \sum_{i=1}^n (X_i - M_n)^2$$

Wird $\text{Var}X$ nur asymptotisch erwartungstreu geschätzt

Weitere Resultate für den Fall $X \approx NV(x, \mu, \sigma)$

$$\hookrightarrow M_n \approx NV(x, \mu, \frac{\sigma}{\sqrt{n}})$$

$\hookrightarrow V_n$ asymptotisch normalverteilt

$\hookrightarrow M_n$ und V_n sind unabhängig Es sei $S_n = \sqrt{V_n}$

$$\hookrightarrow T_n = \frac{M_n - \mu}{S_n} * \sqrt{n} \approx Stu(x, n-1)$$

$$\hookrightarrow \frac{n-1 * S_n^2}{\sigma^2} \approx ChiQ(x, n-1)$$

Schätzung einer Kovarianz

Kovarianz zweier Zufallsgrößen X und Y

$$\text{Cov}(X, Y) = E((X - EX) * (Y - EY))$$

$((x_1, y_1), \dots, (x_n, y_n))$ sei konkrete Stichprobe zu (X, Y)

Schätzwert für Cov : $x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \quad y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$

$$\text{cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n [(x_i - \underbrace{m_n(x)}_{\text{emp Mittel zu x}}) * (y_i - m_n(y))]$$

Schätzung der Korrelation

$$\text{korr}(x, y) = \frac{\text{cov}(x, y)}{\sqrt{\sum_{i=1}^n (x_i - m_n(x))^2 * \sum_{i=1}^n (y_i - m_n(y))^2}}$$

Schätzung einer Kovarianzmatrix zu einem Zufallsvektor $\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$:

Voraussetzung: hohe Anzahl von Realisierungen

Ergebnis: $\begin{pmatrix} \text{cov}(x_1, x_1) & \text{cov}(x_1, x_2) & \dots & \text{cov}(x_1, x_n) \\ \dots & & & \\ \text{cov}(x_1, x_n) & \dots & \dots & \text{cov}(x_n, x_n) \end{pmatrix}$ Voraussetzung: Stichprobenumfang \gg Dimension des Zufallsvektors

2.3. Intervallschätzungen

Synonym: Bereichs-Schätzungen

Aufgabenstellung: Berechnung von $P(\text{—Parameterwert—Schätzwert—} \in \text{Intervall})$

Wichtige Voraussetzung (für die folgende Aufgabe)

$X \approx NV(x, \mu, \sigma)$

(X_1, \dots, X_n) sei mathematische Stichprobe zu X

Aufgabe 1:

$\mu = EX$ unbekannt und zu schätzen

$\sigma^2 = Var X$ bekannt

$$M_n = \frac{1}{n} \sum_{i=1}^n X_i \approx NV(x, \mu, \frac{\sigma}{\sqrt{n}})$$

Nach ZGS gilt:

$$\begin{aligned} 0.95 &= P(-1.96 < \frac{M_n - \mu}{\frac{\sigma}{\sqrt{n}}} \leq 1.96) \\ &= P(M_n - \frac{1.96}{\sqrt{n}} * \sigma < \mu \leq M_n + \frac{1.96}{\sqrt{n}} * \sigma) \end{aligned}$$

M_n ist Zufallsgröße \rightarrow zufällige Intervallgrenzen

Interpretation:

Man kann mit W von 0.95 (Konfidenzniveau) darauf vertrauen, dass μ im angegebenen Intervall liegt.

Das gilt für jede Realisierung m_n von M_n . Also: Man berechne die Intervallgrenzen (mit m_n statt M_n)

μ liegt dann im Intervall mit W 0.95

Bemerkung:

(a) Falls X nicht normalverteilt ist, ist M_n dennoch asymptotisch normalverteilt

(b) Ist σ nicht bekannt, kann (notfalls) V_n verwendet werden

Aufgabe 2:

wie Aufgabe 1, aber jetzt sei σ unbekannt

Nutzung der Student'schen T-Funktion

$$V_n' = \frac{1}{n} \sum_{i=1}^n (X_i - M_n)^2 \quad S_n' = \sqrt{V_n'}$$

$$T_n = \frac{M_n - \mu}{S_n'} * \sqrt{n-1}$$

Satz: $T_n \approx Stu(x, n-1)$

Konstruktion von Intervallgrenzen T_l, T_r

Vorgabe eines Konfidenzniveaus α (meist 0.95)

Bestimmung von t' si, dass $P(-t' < T_n \leq t') = \alpha$

Berechnung der Zufallsgrößen

$$T_l = -\frac{s'_n * t'}{\sqrt{n-1}} + M_n \quad T_r = \frac{s'_n * t'}{\sqrt{n-1}} + M_n$$

Dann gilt

$$\alpha = 0.95 = P(-t' < T \leq t')$$

$$P(-t' < \frac{M_n - \mu}{s'_n} * \sqrt{n-1} \leq t')$$

$$P(-\frac{s'_n * t'}{\sqrt{n-1}} + M_n < \mu \leq \frac{s'_n * t'}{\sqrt{n-1}} + M_n) \\ = P(T_l < \mu \leq T_r)$$

Einsetzung konkreter Realisierung x_i für $X_i \rightarrow$ konkrete Intervallgrenzen

Aufgabe 3:

2-seitiges Konfidenzintervall für σ gesucht Es sei $\mu = EX$ unbekannt

$$V_n = \frac{1}{n-1} \sum_{i=1}^n (X_i - \underbrace{M_n}_{\text{emp. Mittelwert}})^2$$

$$\chi^2 = \frac{n-1}{\sigma^2} * V_n^2 = \frac{1}{\sigma^2} * \sum_{i=1}^n (X_i - M_n)^2$$

Satz:

$$\chi^2 \approx \text{ChiQ}(x, n)$$

Vergabe eines Konfidenzniveaus α (meist 0.95)

Bestimmung von t_l , so dass $P(\chi^2 \leq t_l) = \frac{\alpha}{2}$

Bestimmung von t_r , so dass $P(\chi^2 > t_l) = \frac{\alpha}{2}$

$\hookrightarrow P(t_l < \chi^2 \leq t_r) = \alpha$ Zum testen sei Hypothese $H : \sigma = \sigma_0$

(a) Einsetzen von σ_0 in χ^2 -Formel

(b) t_l, t_r berechnen

(c) Konkrete Stichprobe in χ^2 -Formel einsetzen - Konkreter χ^2 -Wert!

$$\text{Test: } \chi^2 \in (t_l, t_r]?$$

- wenn ja: Es gibt keinen Grund, H abzulehnen.

- wenn nein: H ist abzulehnen, weil bei Richtigkeit ein unwahrscheinliches Ereignis mit W $1 - \alpha$ eingetreten wäre, was unglaublich ist.

$P(\text{Fehler 1. Art}) = P(\text{Ablehnung zu Unrecht}) = 1 - \alpha$

$P(\text{Fehler 2. Art}) = P(\text{Nicht-Ablehnung zu Unrecht}) = \text{keine Aussage möglich (ohne weiteres)}$

Aufgabe 4: wie Aufgabe 3, aber $\mu = EX$ bekannt

V'_n in χ^2 -Formel verwenden (Dividieren durch n , μ statt M_n)

ChiQ(x,n-1) verwenden

Ansonsten analog vorgehen

2.4. Maximum-Likelihood-Schätzmethode

$\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$ - konkrete Stichprobe aus Grundgesamtheit

$$[R, BM, F_X(x, t)]$$

$t = \begin{pmatrix} t_1 \\ \vdots \\ t_n \end{pmatrix}$ unbekannter Punktvektor, $t \in D$ möglicherweise bekannter Bereich

(a) X hat diskrete Verteilung; k Werte möglich: a_1, \dots, a_k ; $p_i = P(X = a_i)$

$p_i(a_i, t_1, \dots, t_n)$ - Funktion des Vektors t

Likelihood-Funktion:

$$L(x_1, \dots, x_n, t_1, \dots, t_m) = \prod_{i=1}^n p_i(x_i, t_1, \dots, t_m)$$

(b) Stetiger Fall

$F_X(x, t)$ sei nach x differenzierbar $\rightarrow f(x) = \frac{d(F_X(x, t))}{dx}$

Likelihood-Funktion:

$$L(x_1, \dots, x_n, t_1, \dots, t_m) = \prod_{i=1}^n f(x_i, t_1, \dots, t_m)$$

ML-Methode zum Finden einer Punktabschätzung für t

Vorschrift: Der Punkt t^* wird als Schätzwert verwendet, für den die Likelihood-Funktion bei vorliegender Stichprobe x maximal wird.

formal: $L(x, t^*) = \underbrace{\max_{t \in D} L(x, t)}$

Existenz, Eindeutigkeit nicht sicher

Mögliche Methoden t^* zu finden:

L nach allen t_i differenzieren, Ableitung = 0 setzen

\hookrightarrow Gleichungssystem (m Gleichungen) lösen

besser: $\ln(L)$ ableiten

$\hookrightarrow \ln(\prod \dots)$ ist eine Summe

Bemerkung: Unter bestimmten Bedingungen ist eine ML-Schätzung

- erwartungstreu
- konsistent
- asymptotisch normalverteilt
- asymptotisch effektiv
- erschöpfend

ML-Schätzung einer Streuung

$X \approx NV(x, 0, \sigma)$ mit $\mu = 0$ und σ unbekannt

$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ sei konkrete Stichprobe vom Umfang $n \geq 2$ mit $x_1 = -2, x_2 = 1$

σ ist mit ML-Methode zu schätzen

$$\begin{aligned} L(-2, 1, \sigma) &= \frac{1}{2\pi\sigma^2} * e^{-\frac{-2*-2}{2\sigma^2}} * e^{-\frac{1*1}{2\sigma^2}} \\ &= \frac{1}{2\pi\sigma^2} * e^{-\frac{5}{2\sigma^2}} \\ L'(-2, 1, \sigma) &= \frac{-2}{2\pi\sigma^3} * e^{-\frac{5}{2\sigma^2}} + \frac{1}{2\pi\sigma^2} * \frac{2*5}{2\pi\sigma^3} * e^{-\frac{5}{2\sigma^2}} \\ &= \frac{-1}{\pi\sigma^3} * e^{\dots} + \frac{5}{2\pi\sigma^5} * e^{\dots} \stackrel{!}{=} 0 \\ &\hookrightarrow 2\sigma^2 = 5 \\ &\hookrightarrow \sigma = \sqrt{\frac{5}{2}} \end{aligned}$$

L'' wäre zu untersuchen für den Maximumsnachweis

Kürzer: ϵ klein, L' programmieren (Matlab)

$$L'(2, 1, \sqrt{\frac{5}{2}} - \epsilon) < 0$$

$$L'(2, 1, \sqrt{\frac{5}{2}}) = 0$$

$$L'(2, 1, \sqrt{\frac{5}{2}} + \epsilon) > 0$$

→ L' monoton wachsend

Vergleich mit Ergebnis der bekannten Schätzformel

$$V'_2 = \frac{1}{2} \sum_{i=1}^2 (x_i - 0)^2$$

bekannter Wert $EX = 0$, nicht M_2

$$\frac{1}{2} * (4 + 1) = \frac{5}{2} \leftarrow \text{Schätzwert für } \sigma^2$$

$$\sqrt{\frac{5}{2}} \leftarrow \text{Schätzwert für } \sigma$$

Vorlesung KW56.1 fehlt

3. Signifikanztests

Begriff:

Es geht nur eine Hypothese über eine Grundgesamtheit

Gegeben: Hypothese H , konkrete Stichprobe

Gesucht: Aussage, ob Stichprobe gegen H spricht

Prinzip

- Annahmen über Grundgesamtheit
- Aufstellen von H
- Vorgabe eines Konfidenzniveaus α (meist 0.95) bzw. Irrtums-Wahrscheinlichkeit $1 - \alpha$
- Definition einer Stichprobenfunktion, Ermittlung über Verteilung
- Benennen eines kritischen Bereichs

Unterscheidung

- verteilungsabhängiger Fall: Ausnahmen über Verteilung der Grundgesamtheit (z.B. NV)
- verteilungsunabhängige Tests: keine solchen Annahmen

3.1. Student-Test

Begriff:

Bezeichnung für Tests, wo Testgröße Student-verteilt ist

3.1.1. Student-Test I

(zum Test eines Mittelwerts) Problematik: Zg $X \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$ konkrete Stichprobe
 μ_0 sei gegeben

H: $EX = \mu_0$ Daher gibt es signifikanten Unterschied? Wichtige Voraussetzung!!!

$$X \approx NV(x, \mu, \sigma) \quad \sigma > 0 \text{ (i.a. unbekannt)}, EX = \mu$$

$$\mu_n = \frac{1}{n} \sum_{i=1}^n X_i \quad V'_n = \frac{1}{n} \sum (X_i - \mu_n)^2$$

Stichprobenfunktion:

$$T_n = \frac{\mu_n - \mu_0}{\sqrt{V'_n}} * \sqrt{n-1} \approx stu(x, n-1)$$

α vorgegeben

Intervall I gesucht mit $P(T_n \in I) = \alpha$

Bestimmung der linken, bzw. rechten Grenze t_l , bzw. t_r aus

$$\frac{1-\alpha}{2} = \int_{-\infty}^{t_l} stu(x, n-1) dx = \int_{t_r}^{\infty} stu(x, n-1) dx$$

Symmetrie von $stu(x, \dots)$ bezüglich 0 $\rightarrow -t_l = t_r$

Definition: $I = [t_l, t_r]$ heißt Konfidenzintervall für T_n zum Konfidenzniveau α .

Dann gilt $P(|T_n| \leq t_r) = 1 - \alpha$

Vorgehen für Student-I-Test:

- (a) $H : EX = \mu_0$
- (b) α festlegen
- (c) Testgröße t_n berechnen (t_n Realisierung von T_n)
- (d) t_l, t_r ermitteln, so dass $P(|T_n| > t_r) < 1 - \alpha$
- (e) Falls $t_n > t_r \rightarrow H$ ablehnen
Falls $t_n \leq t_r$, spricht nicht gegen H

Fehler 1. Art: Ablehnung einer zutreffenden Hypothese (W dafür $1 - \alpha$)

Fehler 2. Art: Nichtablehnung einer falschen Hypothese

3.1.2. Student-Test II

(Vergleich zweier Mittelwerte)

Synonym: doppelter t-Test

Problem: Zg X,Y unabhängig

2 konkrete Stichproben:

$$\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \quad \text{und} \quad \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

Gilt $EX = EY$?

Voraussetzung: X und Y normalverteilt mit $VarX = VarY$ (i.a. unbekannt)

Beispiel: Reißfestigkeit von Stahlseilen, die nach verschiedenen Verfahren hergestellt werden

Berechnung von $M_M(\mathbf{X}), V'_m(\mathbf{X}), M_n(\mathbf{Y}), V'_n(\mathbf{Y})$

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_m \end{pmatrix}$$

Stichprobenfunktion: Es sei $k = m + n$

$$T_k = \frac{M_m(\mathbf{X}) - M_n(\mathbf{Y})}{\sqrt{(m-1)V'_m(\mathbf{X}) + (n-1)V'_n(\mathbf{Y})}} * \sqrt{\frac{m * n * (m + n - 2)}{m + n}}$$

Satz: Falls $EX = EY$, ist T_k student-verteilt mit k Freiheitsgraden
Vorgehen:

- (a) H: $EX = EY$
- (b) α festlegen
- (c) t_k berechnen (konkrete Stichprobe in T_k -Formel einsetzen)
- (d) t_r bestimmen wie zuvor
- (e) Falls $|t_k| > t_r$, H ablehnen, sonst nicht ablehnen

Fehler 1./2. Art möglich

3.2. Anpassungstests

syn.: Nichtparametrische Tests

Zg $X \approx F(x), F(x)$ unbekannt

Nichtparametrische Hypothese: Hypothese über Gestalt von $F(x)$

Anpassungstest: Test einer solchen Hypothese (Es geht nicht um Parameter)

Konkrete Stichprobe $\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$ muss vorliegen

$Emp_n(x)$ weicht nur wenig von $F(x)$ ab.

Vorgehen:

- Hypothese bzgl. $F(x)$ aufstellen
- geeignete Stichprobenfunktion definieren
- Test, ob Funktionswert in bestimmten Intervall liegt

3.2.1. Kolmogorow-Test

Vorgehen:

1. empirische Verteilungsfunktion $emp_n(x)$ berechnen aus Stichprobe
2. d_n berechnen (Realisierung von D_n)
3. Konfidenzniveau α wählen
4. α -Quantil der Kolmogorow-Verteilungsfunktion $K(x)$ berechnen
z.B. $K(1.359) > 0.95 = \alpha$
5. Gilt $\sqrt{n}d_n \leq 1.359$?
Ja, dann besteht kein Grund die Hypothese abzulehnen.
Nein, dann ablehnen.

Fehler 1. und 2. Art möglich.

3.2.2. Kolmogorow-Smirnow-Test

Problem: 2 Stichproben gegeben

Haben wir dieselbe Verteilungsfunktion?

(Wird hier nicht behandelt, nur der Vollständigkeit halber)

3.2.3. Der χ^2 -Test

Allgemein: ein Test, bei dem Testgröße (annähernd) χ^2 -verteilt ist.

Bsp.:

χ^2 -Streuungstest zum Test einer Hypothese bezüglich σ bei Normalverteilung

χ^2 -Anpassungstest (Darum geht es hier)

$X - Zg \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}$ -math. Stichprobe

$\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$ -konkrete Stichprobe

Hypothese H: $X \approx F(X)$

x-Achse wird in k paarweise disjunkte Mengen M_i zerlegt

$M_i = \{x : t_i < x \leq t_{i+1}\} \quad i = 1, \dots, k$

Setze:

$$p_i = F(t_{i+1}) - F(t_i)$$

A_i - absolute Zahl der Werte aus der math. Stichprobe, die in das Intervall M_i reinfallen.

a_i - absolute Zahl der Werte aus der konkreten Stichprobe, die in das Intervall M_i gefallen sind

$n * p_i$ - entsprechende „theoretische“ Häufigkeiten

Empfehlung: t_1, \dots, t_{k+1} so wählen, dass $\forall i : a_i \geq 10$

Pearson'sche Stichprobenfunktion χ^2

$$\chi^2 = \sum_{i=1}^k \frac{(A_i - n * p_i)^2}{n * p_i}$$

Es sei $F_n(x) = P(\chi^2 \leq x)$

Satz: $\lim_{n \rightarrow \infty} F_n(x) = ChiQ(x, k-1)$ (siehe WR 2.3)

Vorgehen beim Test:

1. Hypothese H: $X \approx F(x)$
2. k festlegen: M_i definieren (d.h. t_i)
3. χ^2 -Wert aus konkreter Stichprobe berechnen
4. Sicherheits-Wert α (=0.95) festlegen
5. Grenzwert g berechnen aus Gleichung

$$\alpha = ChiQ(g, k-1)$$

6. Test $\chi^2 \leq g$?
 Ja \rightarrow kein Grund zur Ablehnung von H
 Nein \rightarrow H wird abgelehnt

Problem: Vernachlässigung der Abhängigkeit von n.

Test ist verlässlich, wenn n groß ist.

Beispiel zum χ^2 -Anpassungstest

Aus einer sehr großen Anzahl von Werkstücken werden n=100 Stücke entnommen. Es

finden sich 22 fehlerhafte Stücke.

Hypothese H: $P(\text{Zufallswerkstück fehlerhaft}) = 0.2$

Problem: Ist H mit Stichprobe vereinbar?

Feststellung: $t=22$ ist die Realisierung einer nach $B(k,100)$ verteilten Zufallsgröße mit $p=0.2$ (, falls H wahr ist)

Aufteilung der Stichprobe:

- 22 fehlerhafte Stücke
- 78 fehlerlose Stücke

Nebenüberlegung:

$$\begin{pmatrix} X_1 \\ \vdots \\ X_{100} \end{pmatrix} X_i = \begin{cases} -1 & \leftrightarrow i\text{-tes Stück fehlerhaft} \\ 1 & \leftrightarrow i\text{-tes Stück fehlerlos} \end{cases}$$

Zerlegung der x-Achse

$$M_1 = (-2, 0] \quad M_2 = (0, 2]$$

$$\hookrightarrow a_1 = 22 \quad a_2 = 78$$

$\rightarrow \chi^2$ -Test anwendbar

$$\begin{aligned} \chi^2 &= \frac{(a_1 - n * p)^2}{n * p} + \frac{(a_2 - n * p)^2}{n * p} \\ &= \frac{(22 - 100 * 0.2)^2}{100 * 0.2} + \frac{(78 - 100 * (0.8))^2}{100 * 0.8} \\ &= \frac{4}{20} + \frac{4}{80} = \frac{1}{4} \end{aligned}$$

Gewünscht sei Sicherheits-Wahrscheinlichkeit $\alpha = 0.99$

g sei Lösung der Gleichung $\alpha = 0.99 = ChiQ(g, 1)$ ($k = 2, k - 1 = 1$)

Es ergibt sich $g = 6.6$, d.h. $P(\chi^2 \geq 6.6) = 0.01 = 1 - \alpha$

$0.25 < 6.6 \rightarrow$ kein Grund zur Ablehnung von H.

4. Korrelations- und Regressionsanalyse

Gegenstand: Abhängigkeiten zwischen Merkmalen

Korrelations-Analyse: Klärung, ob linearer Zusammenhang besteht.

Regressions-Analyse: Untersuchung der Form des Zusammenhangs

4.1. Korrelations-Analyse

Siehe 2.2 Punktschätzungen

$\text{korr}(x,y)$ schätzt $\text{Korr}(X,Y)$ - i.a. nicht erwartungstreu.

x,y - Stichproben (Vektoren), X,Y - 2 Zufallsgrößen Falls $\text{Korr}(X,Y)=0$, ist die Schätzung doch erwartungstreu

Zusätzliche Voraussetzung:

$\begin{pmatrix} x \\ y \end{pmatrix}$ habe eine 2D-NV

Unabhängigkeit \leftrightarrow Unkorreliertheit

Ziel: Unabhängigkeits-Test

$$T = \frac{\text{Korr}(X,Y) * \sqrt{n-2}}{\sqrt{1 - \text{Korr}(X,Y)^2}}$$

Hypothese H: $\text{Korr}(X,Y) = 0$

Satz: T student-verteilt mit n-2 Freiheitsgraden ($\text{Stu}(x,n-2)$)

Realisierung von T:

$$t = \frac{\text{korr}(x,y) * \sqrt{n-2}}{\sqrt{1 - \text{korr}(x,y)^2}}$$

α wählen

t_l, t_r bestimmen, so dass

$$P(T \in (t_l, t_r]) = \alpha \text{ (unter H)}$$

$t \in (t_l, t_r)$?

Ja \rightarrow nichts spricht gegen Unabhängigkeit ($\stackrel{\text{hier}}{=}$ Unkorreliertheit)

Nein \rightarrow H verwerfen

4.2. Regressionsanalyse

$\begin{pmatrix} x \\ y \end{pmatrix}$ - Zufallsvektor

von Interesse: $y(x) = E(Y|X = x)$

Graph heißt Regressionskurve.

linearer Fall: Regressionsgerade

Regression 1. Art: Ermittlung der R-Kurve

Regression 2. Art: a,b so bestimmen (im lin. Fall)

$$E(Y - aX - b)^2$$

minimal wird.